

Regularización no-negativa de Next-Generation Reservoir Computing

ante mal condicionamiento y shocks: registro de avance
(Artículo 4: línea SSCR)

Norman Reynaldo Sabillón Castro

Maestría en Matemática, Universidad Nacional Autónoma de Honduras

sabillonrey2004@gmail.com

12 de agosto de 2026

Resumen

Este documento registra el avance de una línea de investigación abierta el 12 de agosto de 2026, motivada por *Stochastically Structured Reservoir Computers* (SSCR, [arXiv:2507.17115](#)) y por un problema abierto de la literatura de *Next-Generation Reservoir Computing* (NG-RC): el mal condicionamiento del bloque de características cuadráticas cuando el número de parámetros D se acerca o supera al número de puntos de entrenamiento T ([arXiv:2505.00846](#)). Se diseñaron y ejecutaron cuatro experimentos controlados, cubriendo un rango de T que antes tenía huecos: un panel anual de instituciones (BCIE, $T \approx 60$), precios semanales de combustibles de Honduras ($T \approx 470$), un panel diario de tipos de cambio latinoamericanos y criptomonedas ($T \approx 3900$), y el atractor de Lorenz63 como control sintético clásico. Con ellos se buscó aislar *cuándo* el mal condicionamiento es dañino para el pronóstico y *cuándo* una restricción de no-negatividad (NNLS) sobre el lector ayuda. Conclusión preliminar: el mal condicionamiento no es dañino *per se*; lo es específicamente cuando se combina con un objetivo estocástico y acotado por abajo (volatilidad realizada), donde NNLS tiene una justificación estadística genuina. Esto se confirmó parcialmente, con mejor potencia estadística, en el experimento de combustibles (hasta $n = 16$ observaciones por evento, apuntando a 4 fechas de calendario frente al $n = 2$ del panel de FX): NNLS gana claramente en 2 de esos 4 eventos, pero no en los otros 2, así que el efecto **no es uniforme ni entre activos ni entre eventos**. En un sistema determinista sin esa estructura (Lorenz), NNLS no ayuda y puede ser peor que mínimos cuadrados sin restringir. Se documentan también los errores de implementación encontrados y corregidos durante el proceso, por transparencia metodológica.

Índice

1. Motivación y pregunta de investigación	1
2. Marco matemático	2
2.1. Estado NG-RC	2
2.2. Diagnóstico de mal condicionamiento	2
2.3. Cuatro lectores comparados	2
3. Experimento 1: Panel anual BCIE ($T \approx 60$)	3
3.1. Refinamiento 12-ago (vía subagente): entidades genuinamente singulares	4
3.2. Refinamiento 12-ago (vía subagente): cobertura pareja y Diebold-Mariano	4

4. Experimento 2: Panel diario FX Latam + crypto ($T \approx 3900$)	5
4.1. κ vs. tamaño de ventana	5
4.2. Pronóstico OOS de volatilidad realizada	5
4.3. Refinamiento 12-ago (vía subagente): día del shock vs. shock en el entrenamiento . .	6
4.4. Refinamiento 12-ago (vía subagente): features no-negativas para NNLS	7
5. Experimento 3: Lorenz63 (control sintético)	8
5.1. Refinamiento 12-ago (vía subagente): grilla de shocks (50 configuraciones)	10
5.2. Refinamiento 12-ago (vía subagente): ruido de medición	11
6. Experimento 4: Combustibles de Honduras ($T \approx 470$, semanal)	12
6.1. Investigación del mecanismo (12-ago, continuación): no es elasticidad de demanda . .	15
6.2. Pista sobre la causa (12-ago, tercera pasada): asimetría de los retornos	16
6.3. Investigación de la fórmula oficial (12-ago, cuarta pasada)	17
7. Errores encontrados y corregidos	17
8. Síntesis y conclusión preliminar	18
9. Trabajo pendiente	19

1. Motivación y pregunta de investigación

El registro de experimentos del proyecto (REGISTRO_EXPERIMENTOS/EXP_ngrc_FRACASO.md) documenta que NG-RC determinista perdió, dos veces, contra un reservorio aleatorio en el panel anual del BCIE ($n \approx 60$ puntos). El diagnóstico original atribuía la derrota a que “los términos cuadráticos amplifican el ruido de 62 puntos anuales”. La literatura reciente (arXiv:2505.00846, arXiv:2407.08641) confirma un mecanismo formal para eso: el número de condición κ de la matriz de covarianza del bloque de características NG-RC crece sin control cuando la dimensión del bloque D compite con el número de muestras T disponibles. Pero esos estudios lo prueban únicamente en sistemas caóticos limpios y largos (Lorenz63), nunca en datos económicos reales ni bajo quiebres estructurales explícitos.

La pregunta que organiza esta línea: *¿el mal condicionamiento de NG-RC es un problema de tamaño de muestra, de ruido, o de shocks discretos? ¿Y en qué régimen ayuda realmente imponer una restricción de no-negatividad (NNLS) sobre el lector, en vez de mínimos cuadrados sin restringir o Tikhonov/Ledoit-Wolf?*

2. Marco matemático

2.1. Estado NG-RC

Dado un escalar observado r_t (retorno diario, o componente x de Lorenz), el estado NG-RC de orden k en el instante t combina los k rezagos lineales y sus productos cuadráticos únicos:

$$\ell_t = (r_{t-k+1}, \dots, r_t) \in \mathbb{R}^k, \quad (1)$$

$$F_t = (\ell_{t,i} \ell_{t,j})_{1 \leq i \leq j \leq k} \oplus \ell_t \in \mathbb{R}^D, \quad D = k + \frac{k(k+1)}{2}. \quad (2)$$

Se **excluye deliberadamente el término constante** del cálculo de κ : al centrar las columnas (paso implícito de PCA y de la covarianza), una columna constante queda en varianza exactamente cero, forzando $\kappa = \infty$ de forma mecánica sin relación con el tamaño de muestra real (ver §7, bug 2).

2.2. Diagnóstico de mal condicionamiento

Para una ventana de entrenamiento de tamaño T , se define

$$\kappa(T) = \text{cond}(\text{cov}(F_{t-T+1:t})) = \frac{\sigma_{\text{máx}}}{\sigma_{\text{mín}}}, \quad (3)$$

la razón entre el mayor y el menor valor singular de la covarianza del bloque de características en esa ventana. $\kappa \rightarrow \infty$ indica una covarianza de rango deficiente (más parámetros que información independiente).

2.3. Cuatro lectores comparados

Dado un objetivo y_{t+1} (retorno $^2_{t+1}$ en FX, o x_{t+1} en Lorenz) y la matriz de diseño $\mathbf{F}$ apilando F_t por fila, se comparan cuatro soluciones al problema de mínimos cuadrados $\mathbf{w}^* = \arg \min_{\mathbf{w}} \|\mathbf{F}\mathbf{w} - \mathbf{y}\|^2$:

$$\text{OLS (sin restringir): } \mathbf{w}^* = \mathbf{F}^+ \mathbf{y} \quad (\text{pseudo-inversa, vía SVD}), \quad (4)$$

$$\text{Ridge/Tikhonov: } \mathbf{w}^* = (\mathbf{F}^\top \mathbf{F} + \lambda \mathbf{I})^{-1} \mathbf{F}^\top \mathbf{y}, \quad \lambda = 0.1 \cdot \frac{\text{tr}(\mathbf{F}^\top \mathbf{F})}{D}, \quad (5)$$

$$\text{Ledoit-Wolf: } \hat{\Sigma}_{LW} = (1 - \alpha) \text{cov}(\mathbf{F}) + \alpha \mu \mathbf{I}, \quad \mu = \frac{\text{tr}(\text{cov}(\mathbf{F}))}{D}, \quad (6)$$

$$\text{NNLS (no-negativo): } \mathbf{w}^* = \arg \min_{\mathbf{w} \geq 0} \|\mathbf{F}\mathbf{w} - \mathbf{y}\|^2. \quad (7)$$

Nota de álgebra lineal (hallazgo del 12-ago): para cualquier matriz simétrica $\mathbf{A}$, $\mathbf{A}$ y $\mathbf{A} + \lambda \mathbf{I}$ comparten los mismos vectores propios: solo cambian los valores propios, desplazados uniformemente por λ . Por lo tanto, Ridge (ec. 5) y Ledoit-Wolf (ec. 6) aplicados como regularizadores de una covarianza *para PCA* seleccionan, en teoría exacta, la misma dirección dominante; la diferencia observada en la práctica proviene de estabilidad numérica al decidir cuál vector propio domina cuando hay valores propios casi empatados en una matriz casi singular, no de que regularicen *la dirección* de la señal.

3. Experimento 1: Panel anual BCIE ($T \approx 60$)

Copia aislada del pipeline de Artículo 2 (`Articulo_4_NGRC_Regularizado_SSRC/experimento/`), protocolo idéntico ($\text{train} \leq 2019$, OOS 2020–2024, máscara hub-and-spoke, P^* vía NNLS por fila). Única variable que cambia entre filas: la compresión $F_t \rightarrow z_t$.

Lectura honesta: Ledoit-Wolf y Tikhonov dan MASE *idéntico* (consistente con la nota de álgebra lineal arriba: mismo eigenvector dominante). El NNLS directo tiene el mejor MASE pero **reduce la cobertura a 8–9 entidades** (vs. 10–11 del resto). Descarta silenciosamente los países de historia corta, el mismo sesgo que ya diagnosticó `EXP_ngrc_FRACASO.md`. No es todavía una comparación limpia en igualdad de cobertura.

Con el bug corregido, el diagnóstico es más matizado que “ $\kappa = \infty$ en todos lados”: la **mediana** de κ es grande pero finita (6,136 para $k = 2$; 41,772 para $k = 3$), mientras que **algunas** combinaciones

Cuadro 1: Comparación bajo protocolo idéntico, config oficial $W = 3$, $\lambda = 0.86$.

Variante	k	MASE	NRMSE	Frob.	entidades
Reservorio aleatorio (referencia)	—	1.240	0.336	1.066	11
NG-RC baseline (PCA sin regularizar)	2	1.110	0.182	0.894	10
NG-RC baseline (PCA sin regularizar)	3	1.035	0.151	0.904	10
NG-RC Ledoit-Wolf	2	1.309	0.175	0.906	10
NG-RC Ledoit-Wolf	3	0.941	0.145	0.920	10
NG-RC Tikhonov	2	1.309	0.175	0.906	10
NG-RC Tikhonov	3	0.941	0.145	0.920	10
NG-RC NNLS directo (sin PCA)	2	0.754	0.193	0.976	9
NG-RC NNLS directo (sin PCA)	3	0.739	0.191	0.984	8

Cuadro 2: Diagnóstico κ corregido (bug 2 aplicado a este experimento el 12-ago).

Variante	k	κ crudo (mediana / máx)	κ usado tras regularizar (mediana / máx)
Baseline	2	6,136 / 3.1×10^{17}	— (no se regulariza)
Baseline	3	41,772 / ∞	— (no se regulariza)
Ledoit-Wolf	2	6,136 / 3.1×10^{17}	8.6 / 15.0
Ledoit-Wolf	3	41,772 / ∞	11.3 / 17.5
Tikhonov	2	6,136 / 3.1×10^{17}	28.0 / 31.6
Tikhonov	3	41,772 / ∞	45.4 / 59.0

entidad $\times$ LOO (las de historia más corta) son **genuinamente singulares** ($\kappa_{\text{máx}} = \infty$ para $k = 3$). Es decir: sí hay entidades donde D (15–28) supera literalmente el número de transiciones disponibles, pero no son la mayoría. Ledoit-Wolf y Tikhonov bajan κ a un rango sano (8.6–59) con mucho más margen del que sugería el diagnóstico sin corregir.

3.1. Refinamiento 12-ago (vía subagente): entidades genuinamente singulares

Un segundo bug, encontrado por el propio subagente al instrumentar κ por entidad (no escondido, documentado en `EXP_kappa_entidades_singulares.md`): la rama `nnls_directo` comparte `Fs_full` con las demás ramas, y esa matriz TAMBIÉN tiene la columna constante centrada a cero por `StandardScaler`. El comentario del código afirmaba “aquí la constante es un intercepto legítimo, no se toca”, pero eso era **incorrecto** dado el código real. Consecuencia: 12 combinaciones entidad $\times$ k mostraban $\kappa_{\text{usado}} = \infty$ por este artefacto, no por escasez real de datos. Verificado numéricamente en el BCIE Systemic Hub ($k=2$): $n_{\text{train}} = 55 \gg D_{\text{features}} = 15$, y aun así $\kappa = \infty$, porque la columna muerta fuerza $\text{rank} = D - 1$. NNLS converge igual (no necesita rango completo), así que el pronóstico de esas entidades es válido pese al κ engañoso.

Descontado ese artefacto, sobre 77 combinaciones entidad $\times$ variante $\times$ k evaluadas, solo **6 son genuinamente singulares**: Colombia (`baseline`, $k = 3$) y Colombia/Panamá/República Dominicana (`nnls_directo`, ambos k). De la lista de “historia corta” del registro del ecosistema (Argentina, República Dominicana), solo República Dominicana reaparece aquí: Argentina no, pero Colombia y Panamá sí, sin estar previamente señaladas. Las combinaciones genuinamente singulares con dato OOS disponible ($n = 1$, evidencia limitada) muestran MASE $1.31\times$ mayor que las no singulares (1.355 vs. 1.033), así que **sí concentran más error**, aunque con una sola observación esto es apenas

sugere, no concluyente.

3.2. Refinamiento 12-ago (vía subagente): cobertura pareja y Diebold-Mariano

Cuadro 3: Comparación con cobertura pareja (8 entidades comunes a las 9 variantes) y prueba Diebold-Mariano (pérdida absoluta, corrección Harvey-Leybourne-Newbold $h = 1$) contra el reservorio, $\alpha = 0.05$.

Variante	MASE (cobertura pareja)	p -valor DM	Significativo
Reservorio (referencia)	1.087	—	—
Baseline $k = 2$	1.041	0.0041	Sí (NG-RC mejor)
Baseline $k = 3$	0.953	0.0505	No
Ledoit-Wolf $k = 2$	1.276	0.0665	No
Ledoit-Wolf $k = 3$	0.941	0.0674	No
Tikhonov $k = 2$	1.276	0.0665	No
Tikhonov $k = 3$	0.941	0.0674	No
NNLS directo $k = 2$	0.751	1.2×10^{-8}	Sí (NG-RC mejor)
NNLS directo $k = 3$	0.739	9.2×10^{-9}	Sí (NG-RC mejor)

Bajo la intersección real de 8 entidades comunes a las 9 variantes (excluye Argentina, Belice y República Dominicana; conserva el hub), que coincide exactamente con la cobertura propia de `nnls_directo` $k = 3$ (confirmando la hipótesis de partida), **el NNLS directo sigue ganando** (MASE 0.739, prácticamente sin cambio respecto a su cobertura propia de 0.739): su ventaja **no era únicamente un artefacto de competir en una canasta más fácil**. La prueba Diebold-Mariano confirma significancia estadística para NNLS directo en ambos k ($p < 10^{-8}$) y para **baseline** $k = 2$ ($p = 0.004$); ninguna variante resultó significativamente *peor* que el reservorio. Limitación honesta: el emparejamiento (entidad, año) para DM exige que ambas series tengan predicción exactamente ese año; con paneles anuales cortos, el número de pares por variante es bajo, lo que limita la potencia de la prueba para las variantes marginales ($p \approx 0.05$ – 0.07).

4. Experimento 2: Panel diario FX Latam + cripto ($T \approx 3900$)

Guión autocontenido, sin TCRA ni topología hub-and-spoke (decisión explícita: cada activo se pronostica solo). Universo: MXN, BRL, COP, CLP, PEN, ARS, GTQ (vs. USD) y BTC, ETH, con 10–15 años de historia diaria real, fuente Yahoo Finance vía `period1/period2`.

4.1. κ vs. tamaño de ventana




Figura 1: Número de condición del bloque cuadrático NG-RC ($k = 3$) en función del tamaño de ventana T , para una serie sin eventos extremos grandes (MXN) frente a series que sí los tienen (ARS: devaluación; COP: colapso de *commodities* 2015–16).

Con miles de puntos reales y el bug 2 corregido, κ es sano (5–50) para la mayoría de series desde $T = 30$. Esto confirma que, en ausencia de eventos extremos, más datos sí resuelven el mal condicionamiento. Pero κ se **dispara a 2.5×10^4 – 5.3×10^5** exactamente cuando la ventana cruza un evento extremo real: un solo día de retorno logarítmico ≈ 0.78 (kurtosis 1402) en ARS, o el colapso de *commodities* 2015–16 para COP/CLP. **El mal condicionamiento de NG-RC, en datos reales, es principalmente un problema de shocks discretos, no de tamaño de muestra.**

4.2. Pronóstico OOS de volatilidad realizada

Objetivo $y_{t+1} = r_{t+1}^2$ (no-negativo por construcción). Ventana móvil $T = 500$, paso 20 días, $k = 3$.




Figura 2: QLIKE mediano por lector, ventanas de calma (escala log).

Cuadro 4: Fracción de predicciones de varianza *negativas* (imposible para r^2), muestra MXN, $n = 125$ ventanas.

Lector	% predicciones negativas
Ridge (Tikhonov)	48.0 %
Reservorio + ridge	45.6 %
OLS sin regularizar	16.0 %
NNLS	10.4 % (reduce, no elimina)

Hallazgo central de este experimento: OLS y Ridge predicen varianza negativa 16–48 % de las ventanas. Al recortar esas predicciones a ≈ 0 , el término $y/\hat{y}$ del QLIKE se dispara ($\approx 10^7$ – 10^8), explicando el QLIKE mediano de Ridge (54.1) frente a 1.45–1.84 del resto. **NNLS es el único método que le gana a la persistencia ingenua por QLIKE en calma** (1.453 vs. 1.836). Aquí la restricción de no-negatividad tiene una justificación estadística real (el objetivo es un cuadrado); no es un capricho heredado del pipeline BCIE. Nota honesta: NNLS restringe los *pesos*, no las *features* (los rezagos lineales de F_t sí pueden ser negativos), por eso reduce pero no elimina la tasa de predicciones inválidas.

4.3. Refinamiento 12-ago (vía subagente): día del shock vs. shock en el entrenamiento

Separar la bandera confirmó la sospecha: con paso de 20 días y shocks raros (2–18 por serie en ~ 3900 días), el walk-forward solo “aterrizó” exactamente sobre un día de shock **2 veces de 1485 ventanas totales**: la categoría “ambos” (entrenamiento contaminado y día de prueba es shock) **no**

ocurrió ni una vez. La bandera original diluía un evento rarísimo dentro de una bolsa de 574 ventanas “entrenamiento con shock”, dando una falsa impresión de tener señal suficiente. En los 2 casos disponibles (PEN 2014-02-05, dudoso; ARS 2023-08-14, devaluación PASO verificada), NNLS tuvo el mejor QLIKE de los 4 métodos ML ambas veces, superando incluso a naive en ARS (1655 vs. 2116): **dirección consistente con la hipótesis, pero $n = 2$ no la demuestra.** Los 5 métodos sub-estiman el shock por una magnitud absoluta casi idéntica; lo que difiere es el QLIKE (sensible a la escala relativa), no el sesgo.

Hallazgo secundario mejor sustentado ($n = 572$, ventanas con shock solo en el entrenamiento): contraintuitivamente, **Ridge y el reservorio MEJORAN** su QLIKE cuando el entrenamiento contiene un shock ($54.1 \rightarrow 6.7$ y $11.4 \rightarrow 7.9$), mientras **NNLS y OLS empeoran** ($1.45 \rightarrow 4.20$ y $1.73 \rightarrow 6.22$). Hipótesis no confirmada aquí: el outlier infla el $\lambda \sim \text{tr}(F^\top F)/D$ heurístico de Ridge/reservorio, reduciendo la frecuencia de predicciones “casi cero” que disparan el QLIKE en calma.

4.4. Refinamiento 12-ago (vía subagente): features no-negativas para NNLS




Figura 3: Trade-off al restringir las *features* del NNLS a no-negativas por construcción ($|\text{rezago}|$ y productos de valores absolutos) frente al NNLS original (rezagos con signo, solo pesos restringidos).

Usando $|\text{rezago}|$ para los términos lineales y productos de valores absolutos para los cuadráticos, **la garantía se cumple exactamente:** 0.00 % de predicciones negativas en las 9 series (vs. 15.82 % del NNLS original, que solo restringe pesos). El QLIKE mejora claramente (mediana $2.075 \rightarrow 1.200$; casos catastróficos con $\text{QLIKE} > 100$ bajan de 17.2 % a 0.9 %). **Pero el MASE típico empeora** (mediana $0.218 \rightarrow 0.374$, +72 %): usar valor absoluto descarta la asimetría de la respuesta de volatilidad al signo del retorno (efecto de apalancamiento, bien documentado en la literatura GARCH). **No es una mejora estrictamente dominante:** es un trade-off real entre garantía estructural completa y precisión típica día a día.

5. Experimento 3: Lorenz63 (control sintético)

Trayectoria RK4 a paso fino ($dt_{\text{integración}} = 0.01$), sub-muestreada cada `skip`= 5 pasos ($dt_{\text{feature}} = 0.05$, siguiendo la convención de Gauthier et al. 2021), 30,000 puntos tras descartar transiente. Objetivo: x_{t+1} directo (no al cuadrado; a diferencia de FX, aquí no hay razón *a priori* de no-negatividad).




Figura 4: Trayectoria $x(t)$ de Lorenz63 (normalizada) con el shock sintético inyectado (spike aditivo de 15σ en un punto conocido). Eje Y partido: sin esto, el shock aplasta la oscilación normal (rango $\approx [-2.3, 2.1]$) contra el fondo del gráfico.




Figura 5: Retrato de fase (x, z) del atractor de Lorenz63 (la “mariposa” clásica, aquí como nube de puntos) con el shock sintético marcado. Al ser una perturbación aditiva sobre el *observable* x y no sobre el estado real (x, y, z) del sistema, el punto del shock cae visiblemente *fuera* de la variedad del atractor. Esto confirma que es una inyección sintética, no una trayectoria físicamente consistente del sistema.




Figura 6: MASE mediano por lector en Lorenz63 (escenario limpio, sin shock).

[bug corregido] La primera corrida (sin `skip`, $dt = 0.02$ directo) daba $\kappa \approx 1.8 \times 10^9$ incluso en la línea base *limpia*: no calzaba con la literatura. Causa: puntos consecutivos de un flujo suave a paso fino son casi idénticos, generando cuasi-colinealidad severa entre rezagos. Corregido con `skip= 5`: κ baja $\sim 1500\times$ a $\approx 1.17 \times 10^6$, mejora sustancial, aunque sigue alto. Interpretación más probable: el atractor de Lorenz tiene dimensión fractal ≈ 2.06 (casi 2D), así que el embebimiento vive cerca de una variedad de baja dimensión incluso con lags bien espaciados (Takens). Pregunta abierta, no resuelta.

Resultado (ya corregido): reservorio (MASE 0.205) y OLS (0.253) ganan por lejos *a pesar de* $\kappa \sim 10^6$, porque el objetivo es determinista y sin ruido: las direcciones casi-degeneradas de F reflejan dinámica real, no ruido, y la SVD de `1stsq` las maneja bien. **NNLS es mediocre aquí** (MASE 0.886, apenas mejor que naive 0.861) porque Lorenz necesita coeficientes de signo mixto: $w \geq 0$ es una restricción estructuralmente equivocada para un sistema sin razón de no-negatividad. Esta es **evidencia independiente** de que la ganancia de NNLS en volatilidad FX viene de la estructura del objetivo, no de que “NNLS siempre ayuda”.

Sobre el shock, la ventana que lo incluye ($n = 25$) muestra κ **más bajo** (5.2×10^4) que las ventanas sin shock (1.17×10^6), lo opuesto al patrón de ARS. Interpretación: en un régimen ya cerca de una variedad de baja dimensión, un punto atípico introduce una dirección genuinamente distinta y puede mejorar el rango efectivo de esa ventana en particular. El MASE apenas cambia con o sin shock (OLS: 0.253 vs. 0.246); el shock sintético de un punto no desestabiliza aquí el pronóstico, a diferencia de lo que se sospecha para ARS en datos reales.

5.1. Refinamiento 12-ago (vía subagente): grilla de shocks (50 configuraciones)

Un solo shock ($n = 25$ ventanas) es evidencia débil. Se repitió sistemáticamente en 5 ubicaciones $\times$ 5 magnitudes ($5\text{--}30\sigma$) $\times$ 2 signos = 50 configuraciones, con barrido *completo* de κ y MASE OOS en cada una.

El patrón “shock baja κ ” se sostiene en el 100% de las 50 configuraciones: no es un artefacto de la ubicación/magnitud/signo original. El signo no importa (κ_{ratio} mediana: 0.0445 para +1, 0.0445 para -1, prácticamente idéntico). La magnitud sí modula la *intensidad*: κ_{ratio} crece monótonamente de 0.0026 (5σ) a 0.74 (30σ), y el efecto se atenúa con shocks más grandes pero nunca se invierte dentro del rango probado; queda abierto si existe un umbral de inversión por encima de 30σ .




Figura 7: ΔMASE (ventana con shock – calma) por lector, en función de la magnitud del shock (mediana sobre 5 ubicaciones $\times$ 2 signos). Ridge se desestabiliza progresivamente; OLS, NNLS y el reservorio permanecen estables.

Hallazgo nuevo, no anticipado: Ridge es el lector *más frágil* ante un shock puntual: su ΔMASE crece de +0.19 (5σ) a +1.26 (20σ), duplicando su error en la ventana con shock, mientras OLS/NNLS/reservorio se mantienen con $|\Delta| < 0.1$ en casi todos los casos (Fig. 7). Hipótesis: el λ heurístico de Ridge ($0.1 \cdot \text{tr}(F^\top F)/D$) se infla de forma inestable con la varianza que aporta el outlier a cada ventana. Esto añade un mecanismo distinto (fragilidad ante outliers) al ya documentado (mediocridad promedio) para explicar por qué Ridge no es un buen lector para Lorenz. **Advertencia metodológica:** parte de la mejora aparente de OLS/naive a magnitudes altas puede ser un artefacto del denominador del MASE (naive_mae se infla dentro de la ventana de entrenamiento contaminada). No se corrigió; se reporta como advertencia de lectura, no como hallazgo de que el shock “ayude”.

5.2. Refinamiento 12-ago (vía subagente): ruido de medición

Se probó ruido gaussiano de medición sobre $x(t)$ en $\sigma_{\text{ruido}} \in \{0, 0.01, 0.05, 0.1, 0.2, 0.5\}$ (fracción de la desviación estándar de la señal), antes de construir el bloque NG-RC, para dos variantes (objetivo limpio / objetivo también ruidoso), 5 semillas de ruido por nivel.

No se encontró un nivel de ruido donde Ridge o NNLS le ganen de forma robusta

a OLS. Ridge nunca gana, en ninguna de las 60 combinaciones semilla×nivel×variante probadas. NNLS solo “empata” con OLS en el nivel de ruido más alto (0.5), y el empate es inestable entre semillas (gana en 3 de 5, pierde en 2 de 5, por márgenes de 0.001–0.018): es convergencia hacia un desempeño igualmente pobre cuando el ruido satura la señal, no una inversión real de cuál método es mejor. **La hipótesis de arXiv:2211.05262 (ruido de medición como ingrediente que falta) NO se confirma** en este montaje específico (predicción a 1 paso, λ heurístico sin ajustar); queda abierto si aparecería con pronóstico multi-paso (donde la literatura de *noise-inspired regularization* suele mostrar beneficios más claros) o con λ ajustado por validación cruzada.

6. Experimento 4: Combustibles de Honduras ($T \approx 470$, semanal)

Cuarto dominio, sugerido por el autor: precios semanales de combustibles de Honduras (Súper, Regular, Diesel, Kerosene), 2017–2026, vía un repositorio propio construido en Python (`Datos_Combustibles_Honduras/`, puerto de una consulta de Power BI que scrapea `proceso.hn`; no se re-scrapea aquí, se lee el repositorio ya construido). Llena el hueco de frecuencia que quedaba explícito entre el panel anual del BCIE ($T \approx 60$) y el diario de FX ($T \approx 3900$): **nunca se había probado** $T \approx 470$ (**semanal**). Mismo bloque NG-RC, mismos lectores y mismo objetivo (retorno², volatilidad realizada) que Experimento 2, para comparabilidad directa. $T_{\text{train}} = 150$ semanas, paso= 4 semanas.




Figura 8: Precios semanales de los 4 combustibles, con las CUATRO ventanas de shock sombreadas: COVID-19 (feb–may 2020), huracanes Eta/Iota (nov–dic 2020), guerra Rusia-Ucrania (feb–jun 2022) y crisis del Estrecho/Medio Oriente 2026 (mar–jun 2026). Las dos últimas fechas de Eta/Iota y Medio Oriente 2026 se *detectaron empíricamente* del mayor movimiento de precio en esas ventanas del calendario (ver `eventos.py`); no se verificaron contra una fuente externa independiente.

Precios por combustible, 2019–2026




Figura 9: Panel por combustible, 2019–2026 (misma sombra de 4 shocks). Cada serie en su propia escala, más fácil de leer la magnitud relativa del movimiento de cada una.

A diferencia de los shocks de un día en FX (que dejaron $n = 2$ para la pregunta “¿ayuda el día del shock?”), aquí se apuntó **directo a las fechas de calendario** en vez de un paso genérico, dando entre 8 y 16 observaciones distintas por evento (2–4 ventanas $\times$ 4 combustibles): mejor potencia estadística que Experimento 2, aunque todavía modesta, especialmente para Eta/Iota ($n = 8$, ventana muy angosta).




Figura 10: QLIKE mediano por lector y categoría (calma + 4 eventos de shock), agregado sobre los 4 combustibles.

Cuadro 5: QLIKE mediano agregado (4 combustibles) por lector y evento de shock.

Lector	Calma	COVID	Eta/Iota	Ucrania	Medio Oriente
Naive	0.436	0.708	0.108	0.220	0.903
OLS	1.240	1.318	0.545	0.207	0.642
Ridge	1.116	0.838	0.035	0.241	1.012
Reservorio	0.718	1.011	0.630	0.480	1.116
NNLS	0.832	0.474	0.204	0.108	0.821

Con 4 eventos en vez de 2, la conclusión inicial (“NNLS gana en shocks”) queda **matizada, no confirmada de forma general**. NNLS gana claramente en 2 de 4 eventos: COVID (0.474 vs. 0.708 de naive) y Ucrania (0.108, la mitad de naive). Pero en **Eta/Iota gana Ridge** (0.035, el mejor de todos) y en **Medio Oriente gana OLS** (0.642), donde NNLS ni siquiera le gana a naive con claridad (0.821 vs. 0.903). No hay un patrón único “NNLS ayuda en todo shock”; hay **cuatro comportamientos distintos** según el evento. Nota sobre Eta/Iota: en la única ventana con QLIKE extremo, OLS y NNLS predijeron el *mismo valor exacto*, así que la restricción de no-negatividad ni siquiera estaba activa ahí (la solución OLS sin restringir ya era no-negativa); con $n = 2$ para esa franja, es una observación, no una conclusión. **Hipótesis nueva, no probada**: la ventaja de NNLS podría depender más de si el shock es *gradual y sostenido* (COVID, Ucrania) que de si es de oferta o de demanda, aunque Eta/Iota (agudo, una semana) y Medio Oriente (gradual, pero gana OLS) no encajan limpiamente en esa historia tampoco, así que queda como pregunta abierta genuina.

El MASE durante COVID y Medio Oriente, en cambio, es catastrófico para **todos** los lectores

por igual (5–10× peor que en calma, sin excepción en ninguno de los dos eventos): ningún modelo entrenado con datos previos podía anticipar esos movimientos; ahí NNLS solo gana en QLIKE, no en MASE.

Matiz honesto adicional: no es uniforme entre combustibles. Desagregado, el patrón de COVID se rompe para Súper y Regular (NNLS ahí tiene QLIKE *peor* que naive: Súper 61.3 vs. 1.4; Regular 53.1 vs. 0.6), mientras que en Diesel y Kerosene NNLS gana con claridad.

6.1. Investigación del mecanismo (12-ago, continuación): no es elasticidad de demanda

Se investigó directamente en vez de especular. **La hipótesis de elasticidad de demanda se descarta:** el mecanismo real ya estaba documentado en el Experimento 2.




Figura 11: Semana 2020-05-11: NNLS predice volatilidad *negativa* (imposible) para Súper/Regular, positiva para Diesel/Kerosene. La predicción cruda, sin recortar a ≥ 0 .

En la semana 2020-05-11, NNLS predijo volatilidad **negativa** para Súper (-0.883) y Regular (-0.522), imposible para un objetivo que es un cuadrado, mientras que para Diesel ($+5.42$) y Kerosene ($+4.56$) predijo positivo (Fig. 11). Al recortar la predicción negativa a ≈ 0 para evaluar QLIKE, $y/\hat{y}$ se dispara: de ahí el QLIKE de 10^{10} . Es el **mismo artefacto que en FX** (§4.3): NNLS restringe los pesos ($w \geq 0$) pero no las *features* de entrada (los rezagos lineales sí pueden ser negativos), así que $F \cdot w$ puede seguir siendo negativo.




Figura 12: Tasa de predicciones NNLS crudas negativas por combustible, sobre toda la serie OOS (no solo en shocks). Súper y Regular son 3–8× más propensos.

Lo nuevo: no fue una casualidad de esa semana. Es un patrón **sistemático** en toda la serie 2017–2026 (Fig. 12): Súper 17.4 % de predicciones negativas, Regular 19.8 %, Diesel 7.0 %, Kerosene 2.3 % ($n = 86$ ventanas cada uno). Súper y Regular son estructuralmente más propensos al artefacto en general, no solo durante el shock; el shock simplemente fue la ocasión en que se manifestó en una ventana evaluada. **La causa económica de fondo** (por qué la dinámica de retornos de gasolina para consumo vehicular produce más patrones de signo que disparan predicciones negativas que la de diesel/kerosene) **queda sin explicar**: se documenta el patrón cuantitativo, no se prueba el mecanismo subyacente. La ventaja agregada de NNLS **no es universal**; depende del combustible, y ahora se sabe por qué a nivel mecánico (aunque no a nivel económico).

6.2. Pista sobre la causa (12-ago, tercera pasada): asimetría de los retornos

Cuadro 6: Asimetría (skew) de los retornos logarítmicos semanales.

Combustible	Skew (serie completa)	Skew (solo calma)
Súper	−1.014	−0.870
Regular	−1.364	−0.829
Diesel	+0.951	−0.519
Kerosene	+0.559	+0.249

Súper y Regular tienen asimetría negativa robusta, que se mantiene incluso excluyendo las 4 ventanas de shock (Tabla 6): caídas de precio más grandes/frecuentes que las subidas, un patrón “sube despacio, baja rápido” típico de gasolina de consumo vehicular. Coincide con el mismo eje que separa la tasa de predicciones NNLS negativas: es plausible como mecanismo, ya que los rezagos lineales del bloque NG-RC heredan esa asimetría.

Honestidad metodológica: la asimetría de Diesel/Kerosene **NO es robusta**. Diesel pasa de +0.951 (serie completa, dominada por el salto de Medio Oriente 2026) a **-0.519** (solo calma, el signo se invierte). Solo la asimetría negativa de Súper/Regular es una propiedad estable de régimen normal; la de Diesel/Kerosene depende de qué shocks entran en la muestra. La hipótesis de asimetría de precio (mecanismo posible: traspaso regulado más rápido de bajadas que de subidas para combustibles de consumo directo en Honduras) es **plausible y cuantitativamente consistente para Súper/Regular, pero no se prueba el mecanismo regulatorio subyacente**. Revisar la fórmula oficial de ajuste de precios de Honduras sería el siguiente paso si se retoma esta línea.

6.3. Investigación de la fórmula oficial (12-ago, cuarta pasada)

Se buscó si existe una asimetría documentada en la fórmula de precios de Honduras. La Secretaría de Energía (SEN), vía su Dirección General de Hidrocarburos y Biocombustibles, fija el precio con el Sistema de Precios de Paridad de Importación: precio de paridad de importación (64–84 % del costo, referencia FOB/CIF acumulada de 22 días de la bolsa de Nueva York más el tipo de cambio), impuestos (21–23 % en gasolinas, 12.54 % en diésel, 4.61 % en kerosina) y márgenes de distribución. La estructura se actualiza cada semana, consistente con la cadencia de los datos usados aquí.

Se confirmó un mecanismo real de asimetría: desde el 1 de mayo hasta agosto de 2026, el Gobierno aplicó un “Apoyo Económico Temporal” que absorbió aproximadamente el 50 % de los *incrementos* de precio en gasolina Regular, diésel y GLP doméstico, sin un mecanismo equivalente documentado para las *rebajas*. Esto es evidencia directa de que Honduras sí usa subsidios asimétricos (que amortiguan solo las subidas) como herramienta de política de combustibles, lo que hace plausible el mecanismo que motivó la hipótesis del skew.

Pero el cierre no es limpio. El programa cubre Regular y Diésel, no Súper ni Kerosene, mientras que el eje de skew encontrado agrupa Súper con Regular (ambos con asimetría negativa robusta) y separa a Diésel de Kerosene (Diésel con skew no robusto, Kerosene con skew positivo débil). Además, el subsidio 2026 es reciente (unos meses) frente a los casi 9 años de historia sobre los que se calculó el skew, así que no puede ser la única causa de una asimetría que ya existía antes de este programa puntual. Es razonable pensar que Honduras aplica subsidios asimétricos de forma recurrente (este es solo el más reciente de una serie de programas similares en años previos, que no se investigaron aquí en detalle), pero **no se logró verificar un mecanismo formal que explique por qué justo Súper y Regular, y no Diésel, cargan la asimetría negativa**. Queda como pregunta abierta, ahora con más contexto institucional que antes pero sin resolver del todo.

Fuentes consultadas: El Heraldo (¿Cómo se define el precio al consumidor de los combustibles en Honduras?), La Tribuna (¿Cuánto suben los combustibles y cuánto cubrirá el Gobierno?), Infobae Honduras (varias notas de 2026 sobre ajustes semanales y subsidios).

7. Errores encontrados y corregidos

Se documentan por transparencia metodológica: ninguno cambia la conclusión central, pero todos alteraron números reportados en algún punto del proceso.

1. **Datos mensuales en vez de diarios (Yahoo Finance).** `range="max"` devuelve barras *mensuales* para pares FX sin avisar (274 puntos en 23 años en vez de ~ 3900). Corregido con `period1/period2` explícitos.
2. **Columna constante forzando $\kappa = \infty$.** `np.cov` centra cada columna; una columna constante queda en varianza exactamente cero tras centrar, forzando $\kappa = \infty$ sin relación con el tamaño

de muestra real. Corregido excluyendo la constante antes de covarianza/PCA (no afecta las comparaciones de MASE, que usan `sklearn.PCA` vía SVD, robusto a esto).

3. `float()` de NumPy 2.x rechaza arrays de forma (1,). El lector “reservorio” fallaba silenciosamente en cada ventana (capturado por un `except Exception` sin registro), dejando la tabla de resultados incompleta sin aviso. Corregido con `float(np.asarray(...).ravel()[0])`.
4. **NNLS con el objetivo recortado a no-negativo por error.** En el primer borrador del experimento de Lorenz se recortó `y_train` a valores ≥ 0 antes de ajustar NNLS. Error conceptual: NNLS solo exige pesos no-negativos, el objetivo puede tener cualquier signo. Corregido antes de ejecutar (no llegó a producir resultados publicados).
5. **Sobremuestreo en Lorenz63.** Ver §7 arriba (control positivo).

8. Síntesis y conclusión preliminar

Los cuatro experimentos, ya con los refinamientos del 12-ago (ejecutados en paralelo vía subagentes, cada uno confinado a su propia subcarpeta de `Articulo_4`, sin tocar el pipeline original de Artículo 2), sostienen una conclusión más precisa que la hipótesis de partida (“NNLS/regularización arregla el mal condicionamiento de NG-RC”):

- El mal condicionamiento **no es dañino *per se***: Lorenz lo tiene ($\kappa \sim 10^6$) y OLS predice casi perfectamente de todos modos, porque el objetivo es determinista. Confirmado con más fuerza: ni siquiera con ruido de medición hasta el 50 % de la señal aparece un régimen donde Ridge/NNLS le ganen de forma robusta a OLS en Lorenz.
- Es dañino específicamente cuando se combina con un **objetivo estocástico y acotado** (volatilidad realizada, FX): ahí las direcciones casi-degeneradas absorben ruido de muestreo que un lector sin restringir amplifica en predicciones sin sentido (varianza negativa).
- **NNLS ayuda cuando el objetivo tiene una razón de no-negatividad genuina**, no como regla general. En Lorenz (sin esa estructura) es mediocre; en volatilidad FX (con esa estructura) es el único método que supera a la persistencia ingenua, y sigue ganando bajo cobertura pareja de entidades en el panel BCIE, con significancia Diebold-Mariano ($p < 10^{-8}$).
- En datos reales (FX) y en Lorenz, el mal condicionamiento se dispara o se atenúa específicamente en ventanas que cruzan **eventos extremos discretos** (shocks), pero la *dirección* del efecto depende del régimen de partida: en FX (bien condicionado en calma) el shock DISPARA κ ; en Lorenz (ya cerca de una variedad de baja dimensión) el shock lo BAJA, de forma consistente en 50/50 configuraciones probadas (ubicación, magnitud $5\text{--}30\sigma$, signo).
- **Hallazgo transversal nuevo**: Ridge es sistemáticamente el lector menos confiable ante shocks, con peor QLIKE en volatilidad FX (54.1 en calma); en Lorenz su error se duplica progresivamente con la magnitud del shock (único lector que no permanece estable). No es solo mediocre en promedio: es frágil específicamente ante outliers, en ambos dominios.
- **Ninguna mejora es gratuita**: NNLS directo (BCIE) gana en MASE pero pierde cobertura; features no-negativas (FX) eliminan predicciones inválidas pero empeoran el MASE típico +72 %; el patrón “shock baja κ ” en Lorenz no se traduce en mejor MASE (el shock ni ayuda ni perjudica el pronóstico ahí). Cada ganancia tiene un costo explícito y medido, no asumido.

- **Confirmación parcial, con mejor potencia (Experimento 4, combustibles semanales, 4 eventos):** apuntando directo a fechas de calendario (COVID-2020, Eta/Iota-2020, Ucrania-2022, Medio Oriente-2026; hasta $n = 16$ por evento vs. $n = 2$ de FX), NNLS gana claramente en **2 de 4** eventos (COVID, Ucrania) pero pierde en los otros 2 (gana Ridge en Eta/Iota, gana OLS en Medio Oriente): **no hay un patrón único** “NNLS ayuda en todo shock”. Dentro de los eventos donde sí gana, tampoco es uniforme entre activos: el patrón de COVID se rompe para Súper/Regular, donde NNLS es de los peores lectores.

9. Trabajo pendiente

1. Apuntar el walk-forward de FX específicamente a fechas conocidas de shock (ARS 2018, ARS 2023-08-14) en vez de un paso genérico de 20 días: la pregunta “¿ayuda la regularización el día del shock?” quedó con $n = 2$, insuficiente para concluir. *Parcialmente atendido* vía Experimento 4 (combustibles, hasta $n = 16$ /evento, 4 eventos) en un dominio distinto; queda pendiente repetir el mismo enfoque dirigido dentro de FX mismo.
2. Investigar la hipótesis nueva de §6 (Experimento 4): ¿la ventaja de NNLS depende de que el shock sea gradual y sostenido (COVID, Ucrania) vs. agudo (Eta/Iota) o de otra propiedad distinta? Solo 4 eventos no alcanza para distinguir hipótesis; haría falta un quinto dominio o más eventos dentro de los ya disponibles.
3. *Resuelto a nivel mecánico* (§6.1): el patrón se rompe porque Súper/Regular tienen $3-8\times$ más tasa de predicciones NNLS negativas que Diesel/Kerosene en toda la serie (17–20 % vs. 2–7 %), mismo artefacto que en FX (pesos restringidos, features no). *Investigado parcialmente* (§6.3): existe un subsidio asimétrico real en Honduras (absorbe alzas, no rebajas) para Regular y Diésel, pero no explica limpiamente por qué el eje de skew separa a Súper+Regular de Diésel+Kerosene. Pendiente real: revisar programas de subsidio anteriores a 2026 y/o la fórmula de márgenes por combustible en más detalle.
4. Probar una variante intermedia para las features del NNLS en FX: linealizar con $|\text{rezago}|$ pero conservar el signo en los productos cruzados, en vez de la garantía completa (todo ≥ 0) que sacrifica más precisión de la necesaria.
5. Investigar si existe una magnitud de shock por encima de 30σ donde el patrón de Lorenz se invierta (no probado, 30σ ya es un valor extremo para ruido de mercado realista).
6. Repetir el experimento de ruido de medición en Lorenz con pronóstico multi-paso (no solo 1 paso) y/o λ de Ridge ajustado por validación cruzada, antes de descartar del todo la hipótesis de *noise-inspired regularization* (arXiv:2211.05262).
7. Investigar por qué Ridge es especialmente frágil ante shocks puntuales (¿es el λ heurístico basado en traza, o es estructural a la regularización L2 en covarianza casi-degenerada?).
8. Probar un regularizador que SÍ cambie la dirección de la señal (no solo la escala numérica): PLS o CCA supervisado hacia el target, en vez de PCA no supervisado $+\lambda I$.
9. Grilla de λ para Tikhonov en el panel BCIE (aquí se usó un único valor heurístico, $0.25 \cdot \text{tr}/D$).
10. Corregir, en `run_ngrc_regularizado.py`, el bug de `Fs_full` compartido entre ramas (§3.2). No se tocó todavía por instrucción explícita de no modificar el script si no hacía falta; no afecta el MASE ya publicado, pero es deuda técnica documentada.

Referencias

- [1] Stochastically Structured Reservoir Computers for Financial and Economic System Identification. [arXiv:2507.17115](#), 2025.
- [2] Stochastic Reservoir Computers. [arXiv:2405.12382](#); versión de revista: *Nature Communications*, 2025.
- [3] Gauthier, D. J. et al. Next generation reservoir computing. *Nature Communications* 12, 5564 (2021).
- [4] On the emergence of numerical instabilities in Next Generation Reservoir Computing. [arXiv:2505.00846](#), 2025.
- [5] How more data can hurt: Instability and regularization in next-generation reservoir computing. [arXiv:2407.08641](#), 2024.
- [6] Adaptive Nonlinear Vector Autoregression: Robust Forecasting for Noisy Chaotic Time Series. [arXiv:2507.08738](#), 2025.
- [7] Susceptible Reservoir Architectures for Regime-Conditional Volatility Forecasting. [arXiv:2607.22491](#), 2026.
- [8] Stabilizing Machine Learning Prediction of Dynamics: Noise and Noise-inspired Regularization. [arXiv:2211.05262](#), 2022.
- [9] Emerging opportunities and challenges for the future of reservoir computing. *Nature Communications* 15, 2056 (2024).