

Inestabilidad, Amplificación de Valores Atípicos y Restricciones de Positividad en Computación por Reservorio de Próxima Generación

Norman Reynaldo Sabillón Castro^{a)}

Departamento de Matemáticas, Universidad Nacional Autónoma de Honduras, Tegucigalpa, Honduras

(Dated: 27 August 2026)

La Computación por Reservorio de Próxima Generación (NG-RC) reemplaza las redes recurrentes aleatorias de alta dimensión por mapas de características polinomiales explícitos de rezagos temporales, ofreciendo una alta eficiencia paramétrica. Sin embargo, su uso práctico suele enfrentar mal condicionamiento numérico y degradación del pronóstico bajo ruido de medición, asimetrías de retornos o shocks exógenos localizados. En este trabajo realizamos una investigación analítica y empírica de estos modos de falla en dinámica caótica y series temporales reales de cola pesada. En primer lugar, demostramos que los bloques cuadráticos de características someten a la regularización Ridge proporcional a la traza ($\lambda \propto \text{tr}(\mathbf{F}^\top \mathbf{F})$) a un escalamiento cuártico ($\sim M^4$) ante shocks de magnitud M , confirmado empíricamente con una pendiente log-log de 3.93 (solo lector Ridge; la heurística de traza de SSRC vive en un espacio de características distinto y se excluye de este ajuste). En segundo lugar, probamos que los desplazamientos espectrales de Tikhonov sobre covarianzas muestrales preservan los autovectores principales de forma idéntica, separando la estabilización de covarianza de la regularización del lector lineal. En tercer lugar, a lo largo de 30 realizaciones estocásticas y 288,420 evaluaciones de ventanas en Lorenz63 (evaluadas mediante un bootstrap por bloques cruzados en dos vías), las activaciones acotadas ($\tanh$) retrasan y reducen la amplificación iterativa del error en comparación con los lectores polinomiales no restringidos en horizontes cortos e intermedios ($H \leq 15$), y la memoria recurrente aporta una ventaja genuina de filtrado de ruido (intervalos bootstrap al 95% en la diferencia media de MASE que excluyen estrictamente el cero); la robustez a shocks, en contraste, depende fuertemente de la condición y no es uniforme en el atractor. Finalmente, en volatilidad diaria de FX y criptomonedas, los mínimos cuadrados no negativos (NNLS) sobre bases estrictamente positivas eliminan las varianzas negativas sin recorte artificial, aunque el lector de reservorio recurrente no resulta competitivo frente a modelos econométricos tradicionales (EWMA, GARCH, GJR-GARCH) cuando se evalúan estadísticas de pérdida sensibles a las colas.

El pronóstico guiado por datos en sistemas dinámicos complejos fue transformado por la Computación por Reservorio de Próxima Generación (NG-RC), que prescinde de grandes redes neuronales aleatorias proyectando la serie temporal en monomios lineales y no lineales de rezagos. Pese a su elegancia, se observa con frecuencia que NG-RC se degrada ante shocks exógenos fuera del atractor y valores atípicos observacionales, ruido de medición o restricciones físicas de no negatividad. En este artículo clarificamos los mecanismos matemáticos que rigen estas fallas y auditamos las afirmaciones empíricas que suelen acompañar a las correcciones basadas en reservorios. Mostramos que las regularizaciones heurísticas escalan a tasa cuártica ($\sim M^4$) ante shocks aislados, sobre-regularizando regímenes en calma. En pronósticos iterados a horizontes discretos ($H \in \{1, 2, 3, 5, 8, 10, 15, 20, 30, 40\}$), los mapas polinomiales retroalimentan errores compuestos en términos cuadráticos, mientras que las activaciones acotadas ($\tanh$) acotan el crecimiento del estado y retrasan la aparición de

divergencia iterada en horizontes intermedios, y un reservorio recurrente aporta un filtrado condicional efectivo bajo ruido. Asimismo, cuando los objetivos tienen cotas físicas o estadísticas (como la volatilidad o precios de energía), los lectores lineales deben restringirse a conos convexos apropiados, si bien la positividad por sí sola no garantiza una calibración probabilística óptima. Nuestros hallazgos ofrecen orientación de diseño concreta, junto con advertencias estadísticas explícitas, para elegir entre expansiones polinomiales deterministas y arquitecturas de reservorio.

I. INTRODUCCIÓN

La Computación por Reservorio (RC) se ha consolidado como un paradigma efectivo para reconstruir, predecir y sincronizar sistemas dinámicos no lineales^{1–5}, con garantías de aproximación universal para la propiedad de estado de eco^{22,23} y perspectivas recientes que revisan los fundamentos teóricos, la pedagogía y los desafíos abiertos del campo^{24,43–45}. Al alimentar una serie temporal $\mathbf{x}_t \in \mathbb{R}^{d_{\text{in}}}$ a una red recurrente fija de alta dimensión (el “reservorio”) y entrenar únicamente una capa de lectura lineal mediante

^{a)} Electronic mail: sabillonrey2004@gmail.com

mínimos cuadrados regularizados, las Redes de Estados de Eco (ESN) estándar evitan el costo computacional y los gradientes desvanecientes del entrenamiento temporal tradicional. Una línea relacionada, los Reservorios con Estructura Estocástica (SSRC)⁶, enriquece esta plantilla con acoplamientos basados en grafos e incrustaciones que preservan estructura para la identificación de sistemas económicos; el ESN disperso y aleatorio que evaluamos en este artículo pertenece a esta familia general de reservorios recurrentes no estructurados, y empleamos la denominación estándar ESN para no confundir ambas arquitecturas.

Recientemente, Gauthier *et al.*⁷ introdujeron la Computación por Reservorio de Próxima Generación (NG-RC), demostrando que para atractores caóticos clásicos, el reservorio aleatorio puede omitirse. Al construir directamente un vector de características $\mathbf{F}_t$ compuesto por k rezagos temporales y sus combinaciones polinomiales únicas, NG-RC logra un rendimiento equivalente o superior con órdenes de magnitud menos parámetros y sin varianza estocástica de inicialización⁸.

Pese a estas ventajas, estudios teóricos y aplicados recientes han puesto de relieve vulnerabilidades críticas en representaciones polinomiales deterministas. Roque dos Santos y Bollt⁹ demostraron que el número de condición κ de la matriz de covarianza de diseño en NG-RC diverge rápidamente a medida que la dimensión de características $D = k + k(k + 1)/2$ se aproxima al tamaño de muestra efectivo T . De forma paralela, Zhang *et al.*¹⁰ evidenciaron que añadir más datos de entrenamiento o incrementar la profundidad de rezagos puede paradójicamente degradar el pronóstico fuera de muestra por mal condicionamiento espectral y amplificación de ruido, extendiendo un hallazgo previo según el cual incluso el conocimiento exacto de la no linealidad gobernante no garantiza una predicción de cuenca robusta ante pequeñas incertidumbres del modelo²⁷. Los esquemas híbridos que combinan reservorios tradicionales y de próxima generación²⁵, junto con la explotación de simetría traslacional para caos espaciotemporal²⁶, ilustran que estos modos de falla están siendo abordados activamente, pero aún no resueltos, por el campo.

Dos alternativas recientes ilustran aún más este esfuerzo de mitigación activa y acotan directamente la novedad reclamada aquí. Cestnik y Martens³² reemplazan el mapa de características polinomial determinista por proyecciones no lineales pseudoaleatorias del vector de rezagos, reportando despliegues autónomos estables y mostrando que una pequeña cantidad de ruido de entrenamiento puede actuar como regularizador. Gauthier, Pomerance y Bollt³³ en cambio particionan el espacio de fases en parches polinomiales locales (NG-RC combinado localmente), evitando la divergencia de una única expansión global de alto grado. Prosperino, Ma y R  th³⁴ advierten adem  s que la dicotom  a polinomio-versus-activaci  n-acotada no es absoluta: el desempe  o depende de qu   tan bien la no linealidad

propia del reservorio corresponde a la del proceso generador de datos subyacente, una correspondencia que no variamos sistem  ticamente en este trabajo. Ninguno de estos tres estudios aisla el mecanismo de escalamiento cu  rtico de traza ante un shock interior aislado, ni separa la contribuci  n causal de la recurrencia frente a la de la activaci  n acotada mediante una ablaci  n controlada a nivel de semilla. Nuestra contribuci  n no es, por tanto, la primera demostraci  n de que representaciones no polinomiales o acotadas pueden estabilizar el pron  stico de NG-RC; es una caracterizaci  n mecanicista de cu  ndo y por qu   falla la expansi  n polinomial est  ndar, y qu   componente arquitect  nico (recurrencia, acotaci  n o regularizaci  n de covarianza) es responsable de la robustez observada.

En aplicaciones pr  cticas, desde flujos geof  sicos hasta volatilidad econom  trica y tasas de cambio de alta frecuencia, las series temporales rara vez son trayectorias limpias y estacionarias^{12,13}. Presentan t  picamente: (i) shocks ex  genos localizados fuera del atractor (eventos aislados, distintos de la variaci  n de r  gimen oculta y persistente estudiada por Hadipour Lakmesari, Kantz y Sorrentino³⁵, que este art  culo no intenta modelar), (ii) ruido de medici  n no gaussiano, y (iii) cotas f  sicas o estad  sticas estrictas (como energ  a cin  tica, precios o varianza realizada $y_t = r_t^2 \geq 0$).

En este trabajo abordamos estos desaf  os mediante un marco anal  tico y emp  rico unificado:

- 1. Mecanismo Anal  tico de Escalamiento Cu  rtico de Trazas ($\sim M^4$):** Demostramos que ante un shock aislado de magnitud M , la traza de la matriz de Gram en NG-RC cuadr  tico escala como $\mathcal{O}(M^4) + \mathcal{O}(M^2) + \mathcal{O}(T(C^2 + C^4))$. Por ende, la heur  stica Ridge proporcional a la traza ($\lambda \propto \text{tr}(\mathbf{F}^\top \mathbf{F})$) infla λ en varios   rdenes de magnitud, sobre-regularizando la ventana completa.
- 2. Invarianza Espectral bajo Regularizaci  n de Covarianza:** Los desplazamientos espectrales de Tikhonov $\mathbf{C} + \lambda \mathbf{I}$ preservan id  nticamente los autovectores principales, lo que muestra que la regularizaci  n de covarianza estabiliza el rango num  rico sin rotar el subespacio principal.
- 3. Robustez Estoc  stica en 30 Semillas y Ablaci  n en Lorenz63:** En 30 realizaciones estoc  sticas y 288,420 registros de evaluaci  n evaluados mediante bootstrap por bloques cruzados en dos v  as, las no linealidades acotadas (tanh) preservan la estabilidad en horizontes multipaso para $H \leq 15$. Bajo ruido ($\sigma = 0.1$), la memoria recurrente ($\mathbf{W}_{\text{res}} \neq \mathbf{0}$) supera a las proyecciones est  ticas con intervalos bootstrap que excluyen el cero. Ante shocks, la respuesta depende de la condici  n: a 15σ , 5 condiciones favorecen al ESN, 3 a Ridge y 2 son inconclusas.
- 4. Restricciones C  nicas y Evaluaci  n Sensible**

a las Colas en Volatilidad: En volatilidad de FX y crypto, NNLS no negativo elimina predicciones negativas sin recorte artificial. No obstante, al evaluar estadísticas de cola (mediana de medias por serie), los modelos econométricos tradicionales (EWMA, GARCH, GJR-GARCH) superan ampliamente a los lectores de reservorio.

II. MARCO MATEMÁTICO Y MECANISMOS ANALÍTICOS

A. Topologías de Espacio de Características: NG-RC vs. ESN Disperso

Sea $x_t \in \mathbb{R}$ un escalar observable en tiempo discreto t . El vector lineal de k rezagos se define como $\ell_t = (x_{t-k+1}, \dots, x_t)^\top \in \mathbb{R}^k$.

1. NG-RC Cuadrático Determinista

La representación cuadrática de NG-RC construye el producto tensorial explícito de monomios:

$$\mathbf{F}_t = \ell_t \oplus \left(\ell_{t,i} \ell_{t,j} \right)_{1 \leq i \leq j \leq k} \in \mathbb{R}^D, \quad (1)$$

con dimensión total $D = k + \frac{k(k+1)}{2}$. La constante se maneja separadamente de la covarianza para evitar deficiencia mecánica de rango.

2. Arquitectura de Reservorio Recurrente Disperso (ESN)

Un reservorio recurrente mapea un vector de entrada $\mathbf{u}_t$ a un estado interno $\mathbf{h}_t \in \mathbb{R}^{d_{\text{res}}}$:

$$\mathbf{h}_t = (1 - a) \mathbf{h}_{t-1} + a \tanh(\mathbf{W}_{\text{in}} \mathbf{u}_t + \mathbf{W}_{\text{res}} \mathbf{h}_{t-1}), \quad (2)$$

donde $a \in (0, 1]$ es la tasa de fuga, $\mathbf{W}_{\text{in}} \in \mathbb{R}^{d_{\text{res}} \times d_{\text{in}}}$ se extrae de $[-1, 1]$ y $\mathbf{W}_{\text{res}} \in \mathbb{R}^{d_{\text{res}} \times d_{\text{res}}}$ es una matriz dispersa escalada a radio espectral $\rho(\mathbf{W}_{\text{res}}) < 1$ (heurística estándar de estabilidad asintótica local del punto de equilibrio nulo, que no garantiza por sí sola la contracción global sin cotas en valores singulares¹⁴). Distinguimos tres casos:

- **ESN-lag:** Entrada de rezagos crudos $\mathbf{u}_t = \ell_t \in \mathbb{R}^k$.
- **ESN-NGRC:** Entrada del bloque polinomial $\mathbf{u}_t = \mathbf{F}_t \in \mathbb{R}^D$.
- **Proyección Estática $\tanh(\mathbf{W}_{\text{res}} = 0)$:** $\mathbf{h}_t = \tanh(\mathbf{W}_{\text{in}} \mathbf{u}_t)$.




FIG. 1. Mediana de $\lambda \propto \text{tr}(\mathbf{F}^\top \mathbf{F})$ en función de la magnitud del shock inyectado M (σ), en escala log-log, medida directamente del experimento en Lorenz63 (§III). El ajuste de ley de potencia, restringido al lector Ridge NG-RC, arroja una pendiente empírica de 3.93, validando el escalamiento $\sim M^4$ predicho por el Teorema 1.

B. Teorema de Inflación Cuártica de Trazas (Escalamiento M^4)

En implementaciones comunes de reservorios y NG-RC, la regularización Ridge¹⁵ se parametriza con la heurística proporcional a la traza:

$$\lambda = \gamma \frac{\text{tr}(\mathbf{F}^\top \mathbf{F})}{D}, \quad \gamma > 0. \quad (3)$$

Teorema 1 (Escalamiento de la Matriz de Gram Cuadrática ante Outliers). Sea $\{x_t\}_{t=1}^T$ una serie temporal compuesta por un proceso base acotado por $|x_t| \leq C$ y un shock aislado en un índice interior t^* , con $k \leq t^* \leq T - k + 1$, de magnitud $x_{t^*} = M \gg C$. Entonces, la traza de la matriz de Gram de NG-RC satisface:

$$\begin{aligned} \text{tr}(\mathbf{F}^\top \mathbf{F}) &= kM^4 + kM^2 + \mathcal{O}(k^2 M^2 C^2) \\ &\quad + (T - k) \mathcal{O}(k^2 (C^2 + C^4)). \end{aligned} \quad (4)$$

Por consiguiente, para parámetros fijos k, T, D, γ y cota base $C \geq 0$, el parámetro λ calculado mediante Eq. (3) escala asintóticamente cuando $M \rightarrow \infty$ como $\lambda = \frac{\gamma k}{D} M^4 + \frac{\gamma k}{D} M^2 + \mathcal{O}(M^2 C^2 + 1) = \frac{\gamma k}{D} M^4 + \mathcal{O}(M^2)$.

Demostración. La traza total es la suma de normas euclidianas al cuadrado:

$$\begin{aligned} \text{tr}(\mathbf{F}^\top \mathbf{F}) &= \sum_{t=1}^T \|\mathbf{F}_t\|_2^2 \\ &= \sum_{t=1}^T \left(\sum_{i=1}^k \ell_{t,i}^2 + \sum_{1 \leq i \leq j \leq k} (\ell_{t,i} \ell_{t,j})^2 \right). \end{aligned} \quad (5)$$

La condición de índice interior garantiza que el shock $x_{t^*} = M$ entra en ℓ_t durante exactamente k pasos consecutivos $t \in [t^*, t^* + k - 1]$ dentro de la ventana de diseño. El bloque lineal $\sum_{i=1}^k \ell_{t,i}^2$ contiene exactamente una entrada M^2 por cada paso afectado, aportando $kM^2 + \mathcal{O}(k^2C^2)$. El bloque cuadrático $(\ell_{t,i}\ell_{t,j})^2$ incluye un término diagonal $(x_{t^*})^4 = M^4$ y $k - 1$ términos cruzados $M^2\ell_{t,j}^2 \leq M^2C^2$, aportando $kM^4 + \mathcal{O}(k^2M^2C^2)$. Los $T - k$ pasos restantes no afectados aportan $(T - k)\mathcal{O}(k^2(C^2 + C^4))$. Sumando sobre los T pasos temporales:

$$\begin{aligned} \text{tr}(\mathbf{F}^\top \mathbf{F}) &= kM^4 + kM^2 + \mathcal{O}(k^2M^2C^2) \\ &\quad + (T - k)\mathcal{O}(k^2(C^2 + C^4)). \end{aligned} \quad (6)$$

Dividiendo entre D se obtiene $\lambda = \frac{\gamma^k}{D}M^4 + \mathcal{O}(M^2)$ para k, T, D, γ y $C \geq 0$ fijos cuando $M \rightarrow \infty$. $\square$

Este teorema explica por qué Ridge heurístico degrada las predicciones: λ se infla en varios órdenes de magnitud (e.g., un incremento mediano de $230.95\times$ en la grilla de shocks de $M = 5\sigma$ a $M = 30\sigma$), penalizando excesivamente los pesos del lector y colapsando las predicciones hacia cero en regímenes en calma posteriores (Fig. 1).

Corolario 1 (Escalamiento de Grado General y el Papel de la Estandarización). *El escalamiento cuártico del Teorema 1 es un caso particular de un efecto más amplio. Para monomios de grado d contruidos sobre coordenadas rezagadas crudas, sin estandarizar, el mismo argumento de conteo da $\text{tr}(\mathbf{F}^\top \mathbf{F}) = \mathcal{O}(M^{2d})$ cuando $M \rightarrow \infty$: un término de grado d contruido enteramente a partir del rezago afectado por el shock escala como M^d , y la traza suma valores de características al cuadrado, dando M^{2d} . Confirmamos esto empíricamente en Lorenz63 midiendo la pendiente log-log de la traza frente a la magnitud del shock para grados $d = 2, 3, 4$ (5 magnitudes $M \in [5, 80]\sigma$, 3 ubicaciones $\times$ 2 signos, 6 condiciones por grado); la pendiente mediana ajustada es 3.985 ($d = 2$), 5.998 ($d = 3$) y 7.998 ($d = 4$), coincidiendo con el exponente predicho $2d$ con un error menor al 0.3% en cada condición. La demostración del Teorema 1 asume coordenadas crudas; si en cambio las columnas de rezago se estandarizan por su propia desviación estándar muestral $\hat{\sigma}_j$ dentro de la ventana de entrenamiento, que a su vez se infla bajo el shock como $\hat{\sigma}_j \sim M/\sqrt{T}$ para un outlier puntual, el valor de característica estandarizado satura en $\mathcal{O}(\sqrt{T})$ sin importar M , amortiguando la inflación de la traza de $\mathcal{O}(M^{2d})$ a $\mathcal{O}(T)$. La fragilidad cuártica (y su generalización M^{2d}) identificada aquí es entonces una propiedad de las matrices de diseño crudas, sin estandarizar, no una característica incondicional de NG-RC. Esta patología no es solo teórica: los experimentos reportados abajo usan un λ seleccionado mediante validación temporal causal anidada, no la heurística de traza de la Ec. (3), y es precisamente eso lo que evita que la explosión cuártica (y su generalización M^{2d}) probada arriba desestabilice en la práctica la línea*




FIG. 2. Reconstrucción en espacio de fase (x, z) que ilustra la excursión de un outlier sintético $(+15\sigma)$ fuera del atractor fractal de Lorenz63.

base Ridge NG-RC (véase el diagnóstico de selección anidada en el material suplementario).

C. Invarianza de Autovectores bajo Desplazamientos Espectrales de Covarianza

Para estabilizar covarianzas mal condicionadas previo a PCA se aplica el desplazamiento de Tikhonov²⁸: $\mathbf{C}_\lambda = \text{cov}(\mathbf{F}) + \lambda_{\text{cov}}\mathbf{I}$.

Proposición 1 (Invarianza Espectral). *Para toda matriz de covarianza simétrica $\mathbf{C} \in \mathbb{R}^{D \times D}$ y $\lambda_{\text{cov}} > 0$, las matrices $\mathbf{C}$ y $\mathbf{C}_\lambda = \mathbf{C} + \lambda_{\text{cov}}\mathbf{I}$ comparten exactamente los mismos subespacios propios.*

Demostración. Sea $\mathbf{C} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^\top$ la descomposición espectral de $\mathbf{C}$, con matriz ortogonal $\mathbf{V}$ y matriz diagonal $\mathbf{\Lambda} = \text{diag}(\mu_1, \dots, \mu_D)$. Entonces:

$$\mathbf{C}_\lambda = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^\top + \lambda_{\text{cov}}\mathbf{V}\mathbf{V}^\top = \mathbf{V}(\mathbf{\Lambda} + \lambda_{\text{cov}}\mathbf{I})\mathbf{V}^\top. \quad (7)$$

Los autovalores se desplazan uniformemente ($\mu_i \mapsto \mu_i + \lambda_{\text{cov}}$), preservando el orden ($\mu_1 \geq \dots \geq \mu_D$) y manteniendo invariantes los subespacios propios (salvo rotaciones internas en autovalores repetidos). $\square$

Por tanto, los desplazamientos de Tikhonov no rotan las direcciones de los subespacios principales; las variaciones prácticas en PCA sin restricciones provienen puramente de ambigüedades numéricas de signo en los algoritmos SVD (y rotaciones unitarias arbitrarias en subespacios propios repetidos o casi degenerados).




FIG. 3. Error de pronóstico iterado multipaso (MASE) a través de horizontes discretos $H \in \{1, 2, 3, 5, 8, 10, 15, 20, 30, 40\}$ parametrizados en tiempos de Lyapunov ($\tau = H \Delta t \lambda_{\max}$, con $\lambda_{\max} \approx 0.9056$). NG-RC polinomial (Ridge y OLS) explota rápidamente más allá de $\tau \approx 0.2$, mientras que las activaciones acotadas (tanh) preservan la estabilidad hasta $\tau \approx 0.68$ ($H = 15$); más allá de $\tau \approx 1.0$, las trayectorias saturan a escala del atractor.

III. EVALUACIÓN DINÁMICA EN LORENZ63

Simulamos el sistema caótico clásico de Lorenz63¹¹:

$$\dot{x} = \sigma(y - x), \quad \dot{y} = x(\rho - z) - y, \quad \dot{z} = xy - \beta z, \quad (8)$$

con parámetros $\sigma = 10$, $\rho = 28$, $\beta = 8/3$, integrando por Runge-Kutta 4 ($dt_{\text{int}} = 0.01$, $\text{skip} = 5$, $\Delta t = 0.05$, semilla de trayectoria 7, 30,000 puntos).

Parametrizamos el horizonte multipaso en unidades del tiempo de Lyapunov principal del sistema objetivo, $\tau = H \Delta t \lambda_{\max}$ con $\lambda_{\max} \approx 0.9056$, que mide la tasa intrínseca de divergencia del flujo físico de Lorenz63, no una propiedad del reservorio mismo. Hart³⁶ muestra que la reconstrucción fiel del atractor depende en cambio de los propios exponentes condicionales de Lyapunov del reservorio y de la suavidad de su variedad de sincronización generalizada con la señal impulsora, con condiciones teóricas de incrustación relacionadas desarrolladas en la Ref. 37; Suetani y Parlitz³⁸ muestran además que la sincronización generalizada débil, la pérdida de estabilidad transversal y el *bubbling* inducido por ruido pueden gobernar la sensibilidad del

pronóstico incluso cuando la sincronización se mantiene nominalmente. No estimamos el espectro condicional de Lyapunov del ESN disperso en este trabajo, por lo que el tiempo de Lyapunov físico reportado a continuación debe leerse estrictamente como una normalización del horizonte de pronóstico, no como una afirmación sobre la tasa de contracción interna del reservorio; estimar ese espectro directamente se identifica en la Sec. V como el experimento de seguimiento de mayor valor.

A. Protocolo Experimental y Métodos

- **Métrica de Pérdida (MASE):** El error fuera de muestra se calcula mediante el Error Escalar Absoluto Medio sobre $T_{\text{train}} = 500$:

$$\text{MASE} = \frac{\frac{1}{H} \sum_{h=1}^H |y_{t+h} - \hat{y}_{t+h}|}{\frac{1}{T_{\text{train}}-1} \sum_{i=2}^{T_{\text{train}}} |y_i - y_{i-1}|}. \quad (9)$$

- **Ventanas Rodantes:** $T_{\text{train}} = 500$ puntos, paso = 40 puntos (738 ventanas a lo largo de la trayectoria). La curva de horizonte de Lyapunov (Fig. 3) evalúa 737 de estos orígenes, ya que el último origen no tiene los $H = 40$ puntos futuros disponibles dentro de la trayectoria y se reserva en vez de rellenarse artificialmente.
- **Hiperparámetros de ESN:** $d_{\text{res}} = 50$, radio espectral $\rho = 0.9$, densidad 0.1, tasa de fuga $a = 1.0$. Estado inicializado en $\mathbf{h}_0 = \mathbf{0}$ con calentamiento causal en el prefijo.
- **Selección Causal de λ :** Validación temporal interna (80% entrenamiento / 20% prueba interna) en la grilla exacta $\lambda/\lambda_{\text{scale}} \in \{10^{-8}, 10^{-6}, 10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1, 10, 100\}$. No se accede jamás a datos futuros.
- **Two-Way Crossed Block Bootstrap:** 2000 réplicas remuestreando bloques temporales de longitud $L = \lceil T_{\text{train}}/\text{step} \rceil = 13$ simultáneamente para todas las semillas, siguiendo el principio de remuestreo por bloques para datos dependientes de Politis y Romano²⁹, y preservando la dependencia cruzada. Para shocks, las 5 ubicaciones se remuestrean conservando ambos signos pareados.
- **Alcance de la Trayectoria y Realizaciones Estocásticas:** Las 30 realizaciones estocásticas en la Tabla I corresponden a extracciones aleatorias independientes de las matrices del reservorio ($\mathbf{W}_{\text{in}}, \mathbf{W}_{\text{res}}$), evaluadas a lo largo de 738 ventanas rodantes sobre una única trayectoria continua y ergódica de 30,000 pasos (semilla 7). Dado que el flujo de Lorenz63 es ergódico y muestrea densamente el atractor a lo largo de este intervalo, las ventanas capturan diversas geometrías del espacio de fases; sin embargo, la sensibilidad a la

inicialización de diferentes trayectorias físicas no se varía aquí y constituye una extensión natural para regímenes multi-atractor.

- **Definición de Victoria por Semilla (Curva de Lyapunov):** Para los conteos de victorias multipaso reportados contra la curva de horizonte de Lyapunov (p. ej., la cifra “1/30 victorias a $H = 40$ ” en la Sec. III.B), una semilla cuenta como victoria para un lector dado si ese lector alcanza un MASE por ventana estrictamente menor que el comparador en más del 50% de las ventanas de evaluación de esa semilla en el horizonte dado: un voto de mayoría por ventana, no una comparación de la mediana de MASE por semilla.

B. Análisis de Resultados y Hallazgos de Ablación

La Tabla I y la Fig. 3 evidencian:

1. **Saturación Acotada y Estabilidad Multipaso en Horizontes Intermedios:** En pronósticos multipaso iterados a través de horizontes discretos $H \in \{1, 2, 3, 5, 8, 10, 15, 20, 30, 40\}$, las activaciones acotadas (tanh) superan a NG-RC polinomial en el **100% de las semillas hasta $H = 10$** ($\tau \approx 0.45$), con intervalos bootstrap estrictamente negativos (Tabla I). A $H = 10$, los errores de NG-RC explotan a $\text{MASE} \approx 2.50$, mientras que los lectores acotados preservan una trayectoria estable ($H = 10$ $\text{MASE} \approx 0.43\text{--}0.74$). No obstante, en horizontes asintóticos ($H = 30, 40$, $\tau \geq 1.36$), las trayectorias alcanzan saturación a escala del atractor donde la proyección estática tanh retiene menor error que el ESN recurrente (MASE mediano 3.04 frente a 5.28 a $H = 40$), y el ESN recurrente deja de superar a Ridge (1/30 victorias a $H = 40$).
2. **Filtrado de Ruido por Memoria Recurrente:** En régimen limpio, la proyección estática tanh es ligeramente más parsimoniosa. No obstante, con ruido ($\sigma = 0.1$ y 0.5), el ESN recurrente supera a la proyección estática en la recuperación de la señal limpia (MASE 0.363 vs 0.398 a $\sigma = 0.1$), con intervalos bootstrap que excluyen el cero en todos los regímenes de ruido. El estado interno $\mathbf{h}_{t-1}$ aporta un desempeño consistente con suavizado temporal adaptativo. Atribuimos esta ventaja a la memoria recurrente en su conjunto; Sedehi *et al.*³⁹ muestran que el desempeño de filtrado de un reservorio truncado está determinado conjuntamente por la poda, la tasa de fuga, el radio espectral y la regularización Ridge actuando en combinación, y aquí no descomponemos estos hiperparámetros individualmente.
3. **Dependencia de la Condición ante Shocks:** La tasa de victoria del 90% ante Ridge a 15σ refleja




FIG. 4. Pérdida QLIKE mediana en función del piso numérico artificial ϵ . Los lectores tradicionales con signo (Ridge, OLS, NNLS con signo) explotan al hacer $\epsilon \rightarrow 0$ debido a predicciones de varianza negativa, mientras que NNLS no negativo se mantiene constante en 1.4498 para $\epsilon \leq 10^{-8}$ y varía levemente a 1.2244 en $\epsilon = 10^{-6}$ porque 3 de los 1,485 pronósticos positivos caen por debajo de dicho umbral.

el agregado entre 30 semillas y 5 ubicaciones. Al desglosar las 10 condiciones (ubicación $\times$ signo), 5 favorecen claramente al ESN, 3 a Ridge y 2 son inconclusas. Esta variación explica por qué el intervalo bootstrap cruzado para la diferencia media cruza el cero ($[-0.233, +3.093]$), descartando una robustez incondicional.

IV. RESTRICCIONES CÓNICAS EN VOLATILIDAD FINANCIERA REAL

A. Objetivos con Cota Inferior y Sensibilidad de Pérdida

El pronóstico de volatilidad realizada $y_{t+1} = r_{t+1}^2 \geq 0$ sigue dominado por líneas base heterocedásticas condicionales y de suavizado exponencial^{30,31}, y se evalúa

TABLE I. Desempeño en 30 realizaciones estocásticas en Lorenz63. Reporta mediana de MASE entre semillas, rangos percentiles 2.5%–97.5%, intervalos Clopper–Pearson al 95% para tasas de victoria frente a Ridge, e intervalos bootstrap en dos vías al 95% sobre la diferencia media pareada (ESN-lag – Ridge; valores negativos favorecen a ESN). Las columnas Ridge y OLS denotan Ridge NG-RC y OLS NG-RC, respectivamente.

Régimen	H	ESN-lag [P2.5,P97.5]	Static-lag	Ridge	OLS	Victoria vs Ridge	Δ media [IC 95%]
Limpio 1-paso	1	0.0292 [0.0161,0.0523]	0.0154 (IQR 0.002)	0.2391	0.2406	100.0% [0.88,1.00]	−0.242 [−0.262,−0.226]
Limpio Multi	5	0.2431 [0.1350,0.4727]	0.1450 (IQR 0.023)	1.5251	1.6044	100.0% [0.88,1.00]	−1.299 [−1.396,−1.203]
Limpio Multi	10	0.7063 [0.3614,1.8185]	0.4265 (IQR 0.051)	2.5320	2.5031	100.0% [0.88,1.00]	−1.290 [−1.539,−1.034]
Ruido 0.1 (Filtrado)	1	0.3628 [0.3402,0.3799]	0.3987 (IQR 0.004)	0.6074	0.6027	100.0% [0.88,1.00]	−0.272 [−0.315,−0.232]
Ruido 0.1 (Observ.)	1	0.4603 [0.4321,0.4859]	0.4869 (IQR 0.006)	0.6831	0.6856	96.7% [0.83,1.00]	−0.236 [−0.281,−0.196]
Ruido 0.5 (Filtrado)	1	0.4744 [0.4468,0.4952]	0.5259 (IQR 0.008)	0.5440	0.5379	100.0% [0.88,1.00]	−0.087 [−0.119,−0.057]
Ruido 0.5 (Observ.)	1	0.7172 [0.6920,0.7367]	0.7451 (IQR 0.005)	0.7484	0.7389	100.0% [0.88,1.00]	−0.058 [−0.091,−0.023]
Shock 15 σ (5 locs)	1	0.2227 [0.1166,0.3610]	0.2192 (IQR 0.062)	0.3305	0.2650	90.0% [0.73,0.98]	+0.927 [−0.233,+3.093]
Shock 50 σ (5 locs)	1	0.4234 [0.2986,0.5711]	0.3380 (IQR 0.100)	0.2215	0.2181	0.0% [0.00,0.12]	+1.131 [−0.316,+3.710]

mediante la pérdida de cuasi-verosimilitud (QLIKE)²⁰:

$$L_{\text{QLIKE}}(y, \hat{y}) = \frac{y}{\hat{y}} - \log\left(\frac{y}{\hat{y}}\right) - 1. \quad (10)$$

QLIKE penaliza severamente la subestimación ($\hat{y} \rightarrow 0$). Al evaluar lectores con signo que producen varianzas negativas, se requiere imponer un piso artificial $\hat{y}_{\text{clipped}} = \max(\hat{y}, \epsilon)$.

En hasta 15 años de datos diarios de 7 divisas latinoamericanas y hasta 10 años para las 2 criptomonedas, cuyo historial más corto refleja su aparición posterior en el mercado ($T \approx 3900$ observaciones agrupadas entre las 9 series), Ridge y OLS generan varianzas negativas en 0.67% y 4.18% de las ventanas. Como muestra la Fig. 4, cuando ϵ desciende de 10^{-6} a 10^{-12} , el QLIKE de Ridge explota en órdenes de magnitud.

TABLE II. QLIKE fuera de muestra en 9 series de divisas y criptomonedas ($T \approx 3900$ observaciones diarias), ordenado por la mediana entre series del QLIKE medio (promedio temporal por serie y luego mediana de las 9 series). La mediana agregada se reporta como referencia. “Ridge Legacy” está recortado en $\epsilon = 10^{-10}$.

Método	Med. de Medias	Med. Agreg.	% Neg.
EWMA ($\lambda = 0.94$)	2.359	1.157	0.00%
GARCH(1,1)	2.383	1.316	0.00%
GJR-GARCH(1,1)	2.456	1.287	0.00%
NNLS No Negativo	2.565	1.450	0.00%
Ridge Legacy (recortado)	3.472	1.475	0.67%
Log-link Ridge	12.19	1.561	0.00%
ESN Disperso (log-readout)	14.33	1.501	0.00%
NNLS Legacy con Signo	66.12	1.490	2.15%
Persistencia Ingenua	2580	1.779	0.00%
OLS Legacy	18552	1.475	4.18%

B. Conos Convexos vs. Monomios con Signo

Restringir $\mathbf{w} \geq \mathbf{0}$ en NNLS estándar¹⁶ no evita salidas negativas si las características contienen rezagos lineales con signo ($\ell_{t,i} < 0$). Para asegurar $\mathbf{F}_t \mathbf{w} \geq 0$

incondicionalmente, las características deben definirse en el ortante positivo $\mathbb{R}_+^D$:

$$\mathbf{F}_t^+ = |\ell_t| \oplus \left(|\ell_{t,i}| |\ell_{t,j}| \right)_{1 \leq i \leq j \leq k}. \quad (11)$$

NNLS no negativo ($|\ell_t|$) y el ESN logarítmico eliminan 100% de varianzas negativas (0.00%). Sin embargo, la positividad no equivale a buena calibración probabilística. La Tabla II muestra que al evaluar la mediana entre series del QLIKE medio, el ESN (14.33) es notablemente inferior a EWMA, GARCH(1,1)^{17,18} y GJR-GARCH(1,1)¹⁹ (2.36–2.46), debido a ventanas raras donde el log-readout predice valores cercanos a cero y $y/\hat{y}$ explota.

El dilema entre positividad y calibración. Esta explosión tiene una explicación teórica directa. El lector logarítmico predice $\hat{y} = \exp(\mathbf{w}^\top \mathbf{h})$, mientras que bajo un modelo de error log-normal $Y = \exp(\mathbf{w}^\top \mathbf{h} + \varepsilon)$ con $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2)$, la esperanza condicional correcta es $\mathbb{E}[Y] = \exp(\mathbf{w}^\top \mathbf{h} + \sigma_\varepsilon^2/2)$. Por la desigualdad de Jensen, $\hat{y}$ subestima entonces $\mathbb{E}[Y]$ por un factor multiplicativo $\exp(\sigma_\varepsilon^2/2) \geq 1$, el mismo mecanismo detrás del estimador de suavizado de Duan para regresión log-lineal²¹; dado que el término $y/\hat{y}$ de QLIKE diverge cuando $\hat{y} \rightarrow 0$, este sesgo resulta asimétricamente costoso. Al aplicar una corrección de suavizado causal, estimando σ_ε^2 solo a partir de residuos logarítmicos fuera de muestra estrictamente anteriores y reescalando $\hat{y} \mapsto \hat{y} \exp(\hat{\sigma}_\varepsilon^2/2)$, el QLIKE medio agrupado del lector logarítmico se reduce de 1152.8 a 8.6 (una reducción relativa de entre 48.5% y 99.9% según la serie), confirmando que la brecha de Jensen explica en buena parte la explosión del QLIKE medio. Sin embargo, la corrección no ayuda de forma uniforme a los pronósticos típicos: el factor de suavizado estimado es en sí mismo de cola pesada (mediana por serie entre 7.4 y 517.8 $\times$, llegando a 6.5×10^5 en la serie más volátil), y la mediana del QLIKE aumenta en 6 de las 9 series al aplicar la corrección, por lo que se reporta aquí como evidencia diagnóstica del mecanismo subyacente y no como una corrección propuesta para producción. Descriptivamente, el ESN gana en 54.7% de ventanas individuales frente a EWMA y en 57.0% frente a GARCH, pero la diferencia media por bootstrap

por bloques es estrictamente positiva a favor de los modelos econométricos. Concluimos que los modelos econométricos siguen siendo el estándar para volatilidad; los conos convexos son esenciales para garantizar no negatividad estructural sin recortes ad hoc, no para superar a GARCH en calibración de colas. Esta distinción es conceptualmente análoga a la separación entre predicción puntual de trayectoria y replicación de propiedades estadísticas discutida por Hramov *et al.*⁴²: nuestros lectores de reservorio se evalúan aquí como predictores puntuales deterministas bajo pérdida asimétrica QLIKE, no como modelos de distribución de probabilidad condicional, y las tasas de victoria por ventana anteriores no deben interpretarse como evidencia de una calibración probabilística superior.

V. DISCUSIÓN Y CONCLUSIONES

Nuestros hallazgos establecen principios operativos para la selección de arquitecturas de reservorio:

1. **Reconstrucción Limpia a Un Paso ($H = 1$):** NG-RC determinista ofrece una parsimonia paramétrica insuperable en atractores limpios de baja dimensión.
2. **Continuación Multipaso ($H \geq 5$):** Las expansiones polinomiales sufren divergencia iterativa de monomios a lo largo de tiempos de Lyapunov; las activaciones acotadas ($\tanh$) limitan el crecimiento del estado y reducen la amplificación de error en horizontes intermedios ($H \leq 15$).
3. **Entornos Ruidosos:** Los reservorios recurrentes ($\mathbf{W}_{\text{res}} \neq \mathbf{0}$) presentan un desempeño consistente con suavizado temporal adaptativo, con una ventaja confirmada por bootstrap sobre proyecciones estáticas bajo ruido de medición.
4. **Shocks y Regularización:** Las heurísticas Ridge proporcionales a la traza deben evitarse con monomios cuadráticos por el mecanismo $\mathcal{O}(M^4)$ (pendiente empírica 3.93, solo Ridge); la regularización exige validación temporal causal. No sostenemos una afirmación incondicional de robustez ante shocks para el reservorio recurrente: a 15σ , solo 5 de las 10 condiciones de ubicación $\times$ signo favorecen claramente al ESN frente a Ridge, 3 favorecen a Ridge y 2 quedan inconclusas.
5. **Observables Físicos con Cota Inferior:** Los lectores lineales deben formularse sobre conos convexos para evitar artefactos de signo, si bien la positividad estructural no es suficiente por sí sola para una óptima calibración de colas. En pérdida de volatilidad sensible a colas (QLIKE), los lectores de reservorio evaluados aquí no superan a los modelos econométricos específicos

del dominio (EWMA, GARCH, GJR-GARCH); las restricciones de positividad resuelven un problema estructural, no uno de precisión de pronóstico.

6. **Alcance: Predictibilidad a Horizonte Finito, No Reconstrucción Climática:** Todos los resultados multipaso evalúan continuación de trayectoria hasta $H = 40$ ($\tau \approx 1.8$ tiempos de Lyapunov); no establecen que la dinámica reconstruida preserve la medida invariante, la integral de correlación o la geometría global del atractor a tiempo infinito. Acotar el crecimiento del estado por sí solo no garantiza la preservación de invariantes dinámicos durante el entrenamiento⁴¹. Evaluar esa noción más fuerte de fidelidad a largo plazo requeriría diagnósticos globales del atractor como los de Fumagalli *et al.*⁴⁰ (densidad invariante, integral de correlación o distancia de Wasserstein entre atractores reconstruidos y de referencia), junto con la estimación del exponente condicional de Lyapunov del reservorio identificada arriba como el experimento de seguimiento de mayor valor.
7. **Paneles Macrofinancieros con Datos Escasos:** Pruebas preliminares sobre un panel regional de préstamos multilaterales (8 entidades, 6 años anuales fuera de muestra; véase el material suplementario) sugieren una ventaja similar de la no negatividad, pero la muestra pequeña deja la comparación de Diebold–Mariano subpotenciada ($p \geq 0.50$); confirmar esta dirección requiere paneles sustancialmente más grandes y queda para trabajo futuro.

MATERIAL SUPLEMENTARIO

Consúltense el material suplementario para validaciones empíricas secundarias en el panel de préstamos del BCIE y precios de combustibles en Honduras, junto con una verificación de generalización en el atractor de Rössler.

AGRADECIMIENTOS

El autor agradece a los revisores anónimos y a la comunidad de computación científica de código abierto. Esta investigación no recibió financiamiento específico de agencias del sector público, comercial o sin fines de lucro.

DECLARACIONES DEL AUTOR

Conflicto de Intereses

El autor declara no tener conflictos de intereses.

Aprobación Ética

Este estudio no involucró participantes humanos, sujetos animales ni datos personalmente identificables; no se requirió aprobación de un comité de ética. Todas las series financieras y de precios utilizadas son registros públicos, agregados y no personales.

Contribuciones del Autor

Norman Reynaldo Sabillón Castro: Conceptualización, Metodología, Software, Análisis Formal, Redacción – Borrador Original, Visualización.

DISPONIBILIDAD DE DATOS Y CÓDIGO

Los datos que respaldan los hallazgos de este estudio y los canales completos de reproducción en Python están disponibles abiertamente en Zenodo en <https://doi.org/10.5281/zenodo.22131199> (Ref.⁴⁶) y en GitHub en <https://github.com/NORSAB/NGRC-Instability-SSRC-Chaos>. Los cierres financieros diarios se obtuvieron mediante la API de gráficos de Yahoo Finance, las aprobaciones de préstamos provienen del portal oficial de datos abiertos del BCIE y los precios semanales de combustibles de Honduras proceden de los paneles públicos publicados por Proceso Digital. Los conjuntos congelados, scripts de simulación y pruebas de validación estadística están incluidos en el paquete abierto de replicación.

- ¹H. Jaeger, “The ‘echo state’ approach to analysing and training recurrent neural networks-with an erratum note,” *German National Research Center for Information Technology GMD Technical Report*, vol. 148, p. 34, 2001, doi: 10.24406/publica-fhg-291111.
- ²W. Maass, T. Natschläger, and H. Markram, “Real-time computing without stable states: A new framework for neural computation based on perturbations,” *Neural Computation*, vol. 14, no. 11, pp. 2531–2560, 2002, doi: 10.1162/089976602760407955.
- ³K. Nakajima and I. Fischer, *Reservoir Computing: Theory, Physical Implementations, and Applications*. Springer, 2021, doi: 10.1007/978-981-13-1687-6.
- ⁴I. B. Yildiz, H. Jaeger, and S. J. Kiebel, “Re-visiting the echo state property,” *Neural Networks*, vol. 35, pp. 1–9, 2012, doi: 10.1016/j.neunet.2012.07.005.
- ⁵J. Pathak, B. Hunt, M. Girvan, Z. Lu, and E. Ott, “Model-free prediction of large spatiotemporally chaotic systems from data: A reservoir computing approach,” *Physical Review Letters*, vol. 120, no. 2, p. 024102, 2018, doi: 10.1103/PhysRevLett.120.024102.
- ⁶L. Banegas and F. Vides, “Stochastically structured reservoir computers for financial and economic system identification,” *IFAC-PapersOnLine*, vol. 59, no. 36, pp. 100–105, 2025, doi: 10.1016/j.ifacol.2026.03.018.
- ⁷D. J. Gauthier, E. Bollt, A. Griffith, and W. A. Barbosa, “Next generation reservoir computing,” *Nature Communications*, vol. 12, no. 1, p. 5564, 2021, doi: 10.1038/s41467-021-25801-2.
- ⁸E. Bollt, “On explaining the surprising success of reservoir computing forecaster of chaos? The effect of internal

- symmetries,” *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 31, no. 1, p. 013108, 2021, doi: 10.1063/5.0024890.
- ⁹E. Roque dos Santos and E. M. Bollt, “On the emergence of numerical instabilities in Next Generation Reservoir Computing,” *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 35, no. 12, p. 123102, 2025, doi: 10.1063/5.0278709.
- ¹⁰Y. Zhang, E. Roque dos Santos, H. Zhang, and S. P. Cornelius, “How more data can hurt: Instability and regularization in next-generation reservoir computing,” *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 35, no. 7, p. 073102, 2025, doi: 10.1063/5.0262977.
- ¹¹E. N. Lorenz, “Deterministic nonperiodic flow,” *Journal of the Atmospheric Sciences*, vol. 20, no. 2, pp. 130–141, 1963, doi: 10.1175/1520-0469(1963)020<0130:DNF>2.0.CO;2.
- ¹²T. L. Carroll, “Dimension of reservoir computers,” *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 30, no. 1, p. 013102, 2020, doi: 10.1063/1.5128898.
- ¹³P. R. Vlachas, J. Pathak, B. R. Hunt, T. P. Sapsis, M. Girvan, E. Ott, and P. Koumoutsakos, “Backpropagation algorithms and reservoir computing in recurrent neural networks for the forecasting of complex spatiotemporal dynamics,” *Neural Networks*, vol. 126, pp. 191–217, 2020, doi: 10.1016/j.neunet.2020.02.016.
- ¹⁴G. Manjunath and H. Jaeger, “Echo state property linked to an input: Exploring a fundamental characteristic of recurrent neural networks,” *Neural Computation*, vol. 25, no. 3, pp. 671–696, 2013, doi: 10.1162/NECO_a_00411.
- ¹⁵A. E. Hoerl and R. W. Kennard, “Ridge regression: Biased estimation for nonorthogonal problems,” *Technometrics*, vol. 12, no. 1, pp. 55–67, 1970, doi: 10.1080/00401706.1970.10488634.
- ¹⁶C. L. Lawson and R. J. Hanson, *Solving Least Squares Problems*. Prentice-Hall, 1974. (Reeditado como SIAM Classics in Applied Mathematics vol. 15, 1995, doi: 10.1137/1.9781611971217; la edición original de 1974 es anterior al registro de DOI.)
- ¹⁷R. F. Engle, “Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation,” *Econometrica*, vol. 50, no. 4, pp. 987–1007, 1982, doi: 10.2307/1912773.
- ¹⁸T. Bollerslev, “Generalized autoregressive conditional heteroskedasticity,” *Journal of Econometrics*, vol. 31, no. 3, pp. 307–327, 1986, doi: 10.1016/0304-4076(86)90063-1.
- ¹⁹L. R. Glosten, R. Jagannathan, and D. E. Runkle, “On the relation between the expected value and the volatility of the nominal excess return on stocks,” *Journal of Finance*, vol. 48, no. 5, pp. 1779–1801, 1993, doi: 10.1111/j.1540-6261.1993.tb05128.x.
- ²⁰A. J. Patton, “Volatility forecast comparison using imperfect volatility proxies,” *Journal of Econometrics*, vol. 160, no. 1, pp. 246–256, 2011, doi: 10.1016/j.jeconom.2010.03.034.
- ²¹N. Duan, “Smearing estimate: A nonparametric retransformation method,” *Journal of the American Statistical Association*, vol. 78, no. 383, pp. 605–610, 1983, doi: 10.1080/01621459.1983.10478017.
- ²²L. Grigoryeva and J.-P. Ortega, “Echo state networks are universal,” *Neural Networks*, vol. 108, pp. 495–508, 2018, doi: 10.1016/j.neunet.2018.08.025.
- ²³L. Gonon, L. Grigoryeva, and J.-P. Ortega, “Approximation bounds for random neural networks and reservoir systems,” *The Annals of Applied Probability*, vol. 33, no. 1, pp. 28–69, 2023, doi: 10.1214/22-AAP1806.
- ²⁴M. Yan, C. Huang, P. Bienstman, P. Tino, W. Lin, and J. Sun, “Emerging opportunities and challenges for the future of reservoir computing,” *Nature Communications*, vol. 15, p. 2056, 2024, doi: 10.1038/s41467-024-45187-1.
- ²⁵R. Chepuri, D. Amzalag, T. M. Antonsen, and M. Girvan, “Hybridizing traditional and next-generation reservoir computing to accurately and efficiently forecast dynamical systems,” *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 34, no. 6, p. 063114, 2024, doi: 10.1063/5.0206232.

- ²⁶W. A. S. Barbosa and D. J. Gauthier, "Learning spatiotemporal chaos using next-generation reservoir computing," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 32, no. 9, p. 093137, 2022, doi: 10.1063/5.0098707.
- ²⁷Y. Zhang and S. P. Cornelius, "Catch-22s of reservoir computing," *Physical Review Research*, vol. 5, no. 3, p. 033213, 2023, doi: 10.1103/PhysRevResearch.5.033213.
- ²⁸A. N. Tikhonov and V. Y. Arsenin, *Solutions of Ill-Posed Problems*. Wiley, 1977. (Anterior al registro de DOI.)
- ²⁹D. N. Politis and J. P. Romano, "The stationary bootstrap," *Journal of the American Statistical Association*, vol. 89, no. 428, pp. 1303–1313, 1994, doi: 10.1080/01621459.1994.10476870.
- ³⁰S.-H. Poon and C. W. J. Granger, "Forecasting volatility in financial markets: A review," *Journal of Economic Literature*, vol. 41, no. 2, pp. 478–539, 2003, doi: 10.1257/002205103765762743.
- ³¹T. G. Andersen and T. Bollerslev, "Answering the skeptics: Yes, standard volatility models do provide accurate forecasts," *International Economic Review*, vol. 39, no. 4, pp. 885–905, 1998, doi: 10.2307/2527343.
- ³²R. Cestnik and E. A. Martens, "Next-generation reservoir computing for dynamical inference," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 36, no. 1, p. 013115, 2026, doi: 10.1063/5.0302319.
- ³³D. J. Gauthier, A. Pomerance, and E. Bollt, "Locality blended next-generation reservoir computing for attention accuracy," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 35, no. 7, p. 073148, 2025, doi: 10.1063/5.0273597.
- ³⁴D. Prosperino, H. Ma, and C. R  th, "Tailored minimal reservoir computing: On the bidirectional connection between nonlinearities in the model and in data," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 35, no. 9, p. 093105, 2025, doi: 10.1063/5.0272793.
- ³⁵S. Hadipour Lakmesari, H. Kantz, and F. Sorrentino, "Reservoir computing for forecasting non-autonomous dynamics with hidden regime variations," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 36, no. 8, p. 081103, 2026, doi: 10.1063/5.0345363.
- ³⁶J. D. Hart, "Attractor reconstruction with reservoir computers: The effect of the reservoir's conditional Lyapunov exponents on faithful attractor reconstruction," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 34, no. 4, p. 043123, 2024, doi: 10.1063/5.0196257.
- ³⁷A. G. Hart, "Generic and isometric embeddings in reservoir computers," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 35, no. 11, p. 111103, 2025, doi: 10.1063/5.0301957.
- ³⁸H. Suetani and U. Parlitz, "Impact of weak generalized synchronization on time series forecasting using reservoir computers," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 36, no. 4, p. 043125, 2026, doi: 10.1063/5.0283017.
- ³⁹O. Sedehi, M. Yadav, M. Stender, and S. Oberst, "Denoising and reconstruction of nonlinear dynamics using truncated reservoir computing," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 35, no. 9, p. 093103, 2025, doi: 10.1063/5.0273505.
- ⁴⁰L. Fumagalli, K. L  dge, J. de Wiljes, H. Haario, and L. Jaurig  , "Data-driven performance measures using global properties of attractors for testing black-box surrogate models of chaotic systems," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 35, no. 11, p. 113121, 2025, doi: 10.1063/5.0283424.
- ⁴¹J. A. Platt, S. G. Penny, T. A. Smith, T.-C. Chen, and H. D. I. Abarbanel, "Constraining chaos: Enforcing dynamical invariants in the training of reservoir computers," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 33, no. 10, p. 103107, 2023, doi: 10.1063/5.0156999.
- ⁴²A. E. Hramov, N. Kulagin, A. N. Pisarchik, and A. V. Andreev, "Strong and weak prediction of stochastic dynamics using reservoir computing," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 35, no. 3, p. 033140, 2025, doi: 10.1063/5.0252908.
- ⁴³A. Amann, K. L  dge, U. Parlitz, and M. Small, "Nonlinear dynamics of reservoir computing: Theory, realization, and application," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 36, no. 6, p. 060402, 2026, doi: 10.1063/5.0342148.
- ⁴⁴K. Inoue, T. Kubota, Q. H. Tran, N. Akashi, R. Terajima, T. Kabayama, J. Guan, and K. Nakajima, "Reservoir computing bootcamp—From Python/NumPy tutorial for the complete beginners to cutting-edge research topics of reservoir computing," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 36, no. 2, p. 023109, 2026, doi: 10.1063/5.0283386.
- ⁴⁵C. Sch  tz, A. White, M. Gelbrecht, and N. Boers, "Machine learning for predicting chaotic systems," *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 36, no. 5, p. 053105, 2026, doi: 10.1063/5.0313297.
- ⁴⁶N. R. Sabill  n Castro, "Replication Package: Instability, Outlier Amplification, and Positivity Constraints in Next-Generation Reservoir Computing," *Zenodo*, 2026, doi: 10.5281/zenodo.22131199. Repositorio en GitHub: <https://github.com/NORSAB/NGRC-Instability-SSRC-Chaos>.